Universität Potsdam
Wirtschafts- und Sozialwissenschaftliche Fakultät
Professur für Volkswirtschaftslehre, insbesondere Märkte, Wettbewerb und Institutionen

Algorithmen im Preiswettbewerb

Inwiefern können Q-Learning Algorithmen repräsentativ für alle Methoden von Dynamic Pricing herangezogen werden?

Hausarbeit

[BVMVWL313] - Markt und Wettbewerb - Seminar zu ausgewählten Themen
412711 Seminar Aktuelle Themen in der empirischen Industrieökonomik
Sommersemester 2022
Inhaber der Professur: Prof. Dr. Lisa V. Bruttel
Tutor: Dr. Andreas Orland

vorgelegt von:
Anastasia Tsymboulova (804385)
Politik und Wirtschaft (6. Fachsemester)
tsymbouova@uni-potsdam.de
Am Stadtrand 59
14478 Potsdam
0331/712415

Abgabedatum: Dienstag, 21. Juni 2022

Inhaltsverzeichnis

Inhaltsverzeichnis I
Abbildungsverzeichnis II
Formelverzeichnis II
1. Einleitung 1
2. Theoretische Grundlagen 3
2.1 Preistheorie 3
2.2 Die Q-Learning Methode 6
3. Methode und Ergebnisse bei Calvano et al. (2020) 8
4. Q-Learning als repräsentativer Beweis für Kollusion 11
5. Fazit 13
Literaturverzeichnis III
Eidesstaatliche Erklärung IV

Abbildungsverzeichnis

Abbildung 1 Wohlfahrt, Quelle: eigene Darstellung 5
Abbildung 2 Deskriptive Statistiken, Quelle: Calvano et al. (2020), S. 3277 9

Formelverzeichnis

Formel 1 Erwartungswert aller Gewinne 6
Formel 2 Q-Funktion 6
Formel 3 Q-Learning Funktion 7
Formel 4 Nachfrage nach Gut i 8
Formel 5 Gewinn der Firma i zum Zeitpunkt t 8
Formel 6 ε-Greedy Modell 8
Formel 7 Qo - Matrix 9

1. Einleitung

Algorithmen sind Problemlösungsverfahren aus der Mathematik und Informatik, welche mit Daten und Formeln alltägliche Aufgaben der modernen Zeit für die Gesellschaft lösen. Von der Google Suche bis hin zur Taschenrechnernutzung erzielen sie übermenschliche Ergebnisse. Effizienter als jeder Mensch es je könnte verarbeiten sie riesige Mengen an Daten auf die abstraktesten und kompliziertesten Weisen, um unsere Entscheidungen täglich zu unterstützen. Ein Teilgebiet der Informatik ist die Erforschung von Künstlicher Intelligenz (KI). Das Forschungsfeld beschäftigt sich mit genau dieser Anwendung von Algorithmen, welche über Berechnungen hinausgehen und versuchen menschliches Lernen, Wahrnehmen und Handeln in Codezeilen nachzuahmen. Eine Methode des Lernens von KIs ist das *Machine Learning.* Wiederum eine Methode dessen ist das *Reinforcement Learning*. Das sind Verfahren, bei denen die *Agents* ohne externe Daten von selbst zum Lernen angewiesen werden. Dafür werden Formeln so eingesetzt, dass mit Daten Erfahrungen berechnet werden könne, die dann beispielsweise zu Parameteranpassungen führen. Dazu kann die Q-Learning Methode herangezogen werden. Um diese geht es auch in der vorliegenden Arbeit. Diese populäre Anwendung kann für zahlreiche Probleme, die eine optimale Policy, also eine qualitativ hochwertige Entscheidungsfindung benötigen, eingesetzt werden. Beispielsweise wurden Q-Learning *Agents* darauf programmiert Videospiele in Rekordzeit zu meistern, Aktien langfristig gewinnbringend zu handeln oder Preise zu setzen, was auch als *Dynamic Pricing* bezeichnet wird. Letztere Preissetzungsalgorithmen sind Gegenstand der Forschung von Emilio Calvano, Giacomo Calzolari, Vincenzo Denicoló und Sergio Pastorello. Diese untersuchten in „Artifical Intelligence, Algorithmic Pricing, and Collusion“ aus dem Jahr 2020, ob Algorithmen zu kollusiven Verhalten durch implizite Preissetzung führen. Genau das wird durch deren Experiment bestätigt, jedoch nur für die Q-Learning Methode und nicht für andere Arten von *Dynamic Pricing*. Das ist jedoch kritisch, da Firmen in der Regel nicht preis geben welche Algorithmen sie verwenden und man daher nur bedingt auf die Grundgesamtheit schließen kann, wenn man nur einen Einzelfall betrachte. Nachdem die theoretischen Grundlagen in dem Abschnitt 2 erklärt wurden und das Paper sowie die Forschungsergebnisse von Calvano et al. (2020) im Kapitel 3 vorgestellt wurden wird genau dieser Kritikpunkt diskutiert. Im abschließenden Fazit werden die Erkenntnisse zusammengefasst und ein Vorschlag zur Behebung dieser Forschungslücke gegeben. Denn, wie im nachfolgenden noch gezeigt wird, führt implizite Preissetzung zu einem Wohlfahrtsverlust, welcher durch Gesetzgeber reguliert werden könnte. Wenn genügend belastbare Ergebnisse von tatsächlichen Anwendungen der Algorithmen auf dem Markt vorliegen kann dem modernen Gespenst des Kapitalismus entgegengewirkt werden. Daher ist das Ziel der vorliegenden Arbeit zu diskutieren, inwiefern denn Q-Learning Algorithmen tatsächlich geeignet sind, um als Repräsentant

für andere Methoden herangezogen zu werden oder, ob es noch mehr Bedarf zum Nachweis von Kollusion gibt. Calvano et al. (2020) ist eines von mehreren Berichten über Kollusion von Q-Learning Algorithmen (Cheng, 2009; Itto & Petit, 2017; Klein, 2021; Lu, Ho, Hong, & Zhang, 2018; Raju, Narahari, & Ravikumar, 2003). Jedoch sind andere KI-Methoden in der Preissetzung weniger erforscht (Chen, Mislove, & Wilson, 2016; Cope, 2007). Es ist nicht möglich eigene weitere empirische Untersuchungen in Rahmen dieser Hausarbeit anzufangen. In dieser Arbeit werden nur Argumente beleuchtet, lediglich wird am Ende ein Vorschlag für ein Forschungsvorhaben vorgestellt. Vorwissen über die Grundlagen der Spieltheorie werden vorausgesetzt, da sie im Rahmen dieser Hausarbeit nicht extra erläutert werden können.

2. Theoretische Grundlagen

2.1 Preistheorie

Die Preistheorie erklärt, wie sich Preise für Güter bilden können, wenn Angebot und Nachfrage, in verschiedenen Marktformen, zusammentreffen (Engelkamp, Sell, & Sauer, 2020, S. 118). Im Rahmen dieser Hausarbeit werden nur die drei Typen von Märkten[1] näher erläutert. Die Vollkommene Konkurrenz[2] mit viele Firmen, das Oligopol mit wenigen und das Monopol mit einem preissetzenden Unternehmen. Alles unter den gängigen Vernachlässigungen von Interdependenzen[3], der Annahme von Symmetrie und dem freien Marktzutritt. Das ist wichtig für die Bedeutung der Preise in den einzelnen Modellen und um die Wirkung von Markt Ein- und Austritten zu erklären. Nur so ist der Preis das Einzige, wovon die Konsumenten ihre Kaufentscheidung abhängig machen. Dadurch fällt der gesamte Gewinn immer dem Anbieter mit dem geringsten Preis zu. (Engelkamp, Sell, & Sauer, 2020, S. 118).

Im Normalfall verläuft die Nachfragekurve fallend und zur Vereinfachung wird ein steigender Grenzkostenverlauf[4] angenommen *(Bofinger, 2020, S. 147)*. Die Angebotskurve entspricht bei vollkommener Konkurrenz dem Verlauf der Grenzkostenkurve der angebotenen Menge. In diesem Fall ist die Firma eine von vielen Preisnehmern, weswegen sie für jede weitere Einheit eines Gutes denselben Preis bekommt. Das ist gleichbedeutend mit konstanten Grenzerlösen, die dem Marktpreis entsprechen. Die Firma wird solange ihre Produktion ausweiten bis die Grenzkosten dem Preis am Markt entsprechen. Da noch mehr Gewinn mit einem Preis unterhalb der Grenzkosten erzielt werden kann, indem mehr produziert wird, wird die Firma auch weiter produzieren, um ihren Gewinn zu maximieren. Da darüber hinaus die Kosten für ein weiteres Gut über dem Preis liegen, denn dann wird kein Gewinn mehr erzielt *(Bofinger, 2020, S. 147)*.

Das ist nicht der Fall, wenn es sich um ein Monopol handelt *(Bofinger, 2020, S. 147)*. Dann ist nur eine Firma auf dem Markt, die den Preis und Menge setzen kann. Schließlich wird das ebenfalls im Gewinnmaximum liegen, welches für ein Monopol in dem Punkt liegt, wo Grenzkosten dem Grenzerlös entsprechen. Ähnlich wie bei Vollkommener Konkurrenz, wo der Grenzerlös dem Marktpreis entspricht und beides der Grenzkosten. Durch den Unterschied, dass ein Monopolist ein Preissetzer und kein Preisnehmer ist variiert der Preis mit der Menge entlang der Preisabsatzfunktion. Die Firma

[1] „[…] Markt als ökonomischer Ort des Tausches definiert, womit die Gesamtheit der Tauschbeziehungen von Anbietern und Nachfragern eines bestimmten Gutes oder einer bestimmten Gütergruppe gemeint ist.“ (Engelkamp, Sell, & Sauer, 2020, S. 118)

[2] Homogenität der Güter; keine persönlichen Präferenzen; keine zeitlichen, räumlichen Differenzierungen, Vollständige Markttransparenz (Engelkamp, Sell, & Sauer, 2020, S. 120)

[3] Viele Märkte sind voneinander abhängig. Ändert sich beispielsweise der Preis für Strom so können alle Produkte teurer werden, die Strom zur Produktion brauchen, da die Kosten steigen. In der Regel werden Modelle unter der ceteris Paribus Annahme betrachtet, um gezielte Aussagen über einzelne Effekte zu treffen (Engelkamp, Sell, & Sauer, 2020, S. 118).

[4] Grenzkosten sind die marginalen Kosten für eine weitere Einheit in der Produktion.

muss abwägen, wie sie ihren Preis setzt. Hoch genug, um keine möglichen Profite zu verpassen, aber nicht zu hoch, um nicht zu viele Kunden zu verlieren. Schließlich wird sich optimale Preis und Menge dort finden, wo die Grenzkosten dem Grenzerlös entsprechen. Analog zu der Situation in der Vollkommenen Konkurrenz, wo der Grenzerlös konstant war. Im Monopol ist der Grenzerlös nun von der Menge abhängig und nicht gleich dem exogen vorgegebenen Marktpreis *(Bofinger, 2020, S. 147)*.

Zwischen den beiden Grenzfällen von vollkommener Konkurrenz und Monopol liegt das Oligopol, wo mehrere Firmen den Markt beeinflussen können (Engelkamp, Sell, & Sauer, 2020, S. 146f). Hier müssen die verschiedenen Akteure ihr Verhalten in der Preissetzung auf die anderen anpassen. Diese gegenseitigen Reaktionen in der oligopolistischen Interdependenz werden in verschiedene Modelle unterteilet. Im Folgenden wird nur der Bertrand-Preiswettbewerb (BPW) erklärt, da dieser die Grundlage für das Q-Learning Modell von Calvano et al. (2020) darstellt. Dabei wird angenommen, dass in einem Duopol zweier Firmen mit denselben Kosten gleichzeitig ihre Preisentscheidung treffen und die Konsumenten wie gehabt zum niedrigeren Preis kaufen werden. Im BPW gibt es nur ein Nash-Gleichgewicht, wenn die Preise der beiden Firmen den Kosten entsprechen. Es wird außerdem angenommen, dass die Kosten konstant sind, also sind auch hier die Kosten für ein weiteres Gut gleich den konstanten Kosten. Es gilt dieselbe Logik wie zuvor im Fall von Vollkommener Konkurrenz. Das wird auch als Bertrand-Paradox bezeichnet, da zwei Firmen genug sind, um dasselbe Marktergebnis wie bei ganz vielen Firmen zu erzeugen. Setzen beide Firmen ihren Preis oberhalb der Kosten teilen sich die Akteure den Gewinn und die Nachfrage gleichmäßig auf. Es besteht die Gefahr, dass einer die gesamte Nachfrage abgreifen will, indem doch ein Preis unterhalb des vorherigen gesetzt wird. In dem Fall greift eine Firma die gesamte Marktnachfrage ab und die andere hat einen Gewinn von 0. Deshalb müssen die Preise von beiden genau den Kosten entsprechen, um diese Gefahr zu verhindern. Denn keine der Firmen wird einen Preis unterhalb der Kosten setzten, um die Nachfrage abzugreifen aber Verlust zu machen. Das Bertrand-Paradox kommt in *one-shot* Preissetzungsrunden vor. Gibt es jedoch eine unbegrenzte Anzahl an Runden, so kann mit der *Trigger*-Strategie auch ein monopolistisches Markergebnis entstehen. (Engelkamp, Sell, & Sauer, 2020, S. 146f).

Kartelle sind Zusammenschlüsse von Firmen, die sich in kooperativen absprachen von Preisen und Mengen auf Märkten kennzeichnen. Gemeinsam maximieren die Firmen ihren Gewinn, indem sie jeweils Monopolpreise setzten ohne die Gefahr, dass eine Firma die andere im Preis unterbietet und die gesamte Marknachfrage abräumt. In Deutschland ist das nach §1 das Gesetz gegen Wettbewerbsbeschränkungen (GWB) verboten. „Vereinbarungen zwischen Unternehmen, Beschlüsse von Unternehmensvereinigungen und aufeinander abgestimmte Verhaltensweisen, die eine Verhinderung, Einschränkung oder Verfälschung des Wettbewerbs bezwecken oder bewirken, sind verboten.“ (Bundesmisterium der Justitz, 2022). Kollusion ist implizites Parallelverhalten von Firmen auf dem-

selben Markt. Diese haben sich nicht direkt geeinigt Preise und Mengen aufeinander abzustimmen und sind der Gefahr ausgesetzt, dass einer von der impliziten Kooperation abweicht. Mit der *Trigger*-Strategie wird sichergestellt, dass so lange kooperiert wird, bis jemand den Preis unkooperativ setzt. Dafür muss die Bedingung gelten, dass der Gewinn bei Kooperation höher ist als bei einer Abweichung von der *Trigger*-Strategie, um eine stabile Kollusion zu erzeugen. Es wird, wie im Kartell, ein Monopolpreis festgelegt und der Gewinn zu selben Anteilen zerlegt. Das ist deshalb problematisch, weil es zu einem Wohlfahrtsverlust kommt, wenn Monopolpreise gesetzt werden. In Abbildung 1 wird das dargestellt. Die Produzentenrente steigt, während die Konsumentenrente sinkt und das graue Dreieck an Rente geht der gesamten Gesellschaft verloren. Deshalb ist die Erforschung von Algorithmen in der Preissetzung so wichtig, wenn sie zur Kollusion führt. So gäbe es nämlich eine neue Variante für Firmen Preise implizit abzusprechen ohne die Befürchtung von Abweichung. Das könnte zu einem immer größeren Wohlfahrtsverlust führen[5].

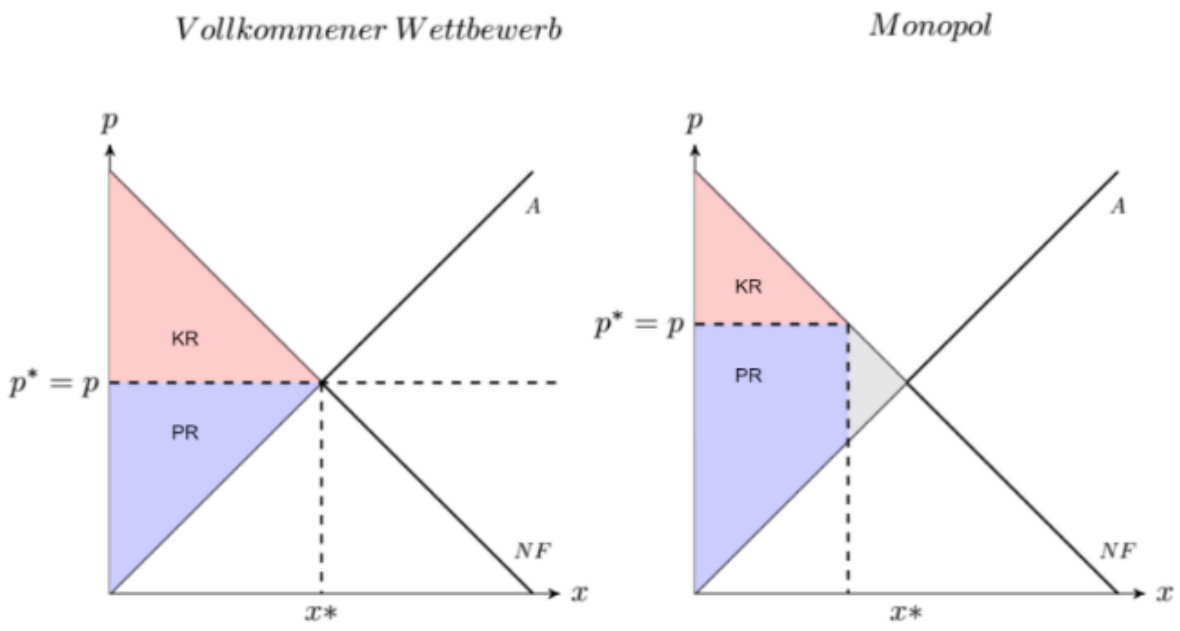

Abbildung 1 Wohlfahrt, Quelle: eigene Darstellung

[5] Verstärkt wird der Wohlfahrtsverlust durch Algorithmische Preissetzung durch die Preisdiskriminierung 3. Grades. Algorithmen bieten die Möglichkeit, gegeben dem Zugang zu den entscheidenden Daten, die volle Zahlungsbereitschaft de Konsumenten abzuschöpfen. Zusätzlich zu dem Preisaufschlag durch monopolistisches Verhalten bei Kollusion passen diese ihre Preise individuell und ohne Probleme an jeden einzelnen Konsumenten an und greifen damit die gesamte Konsumentenrente ab und erzeugen einen höheren Wohlfahrtsverlust. Ein Grund mehr warum *Dynamic Pricing* weiter erforscht werden sollte.

2.2 Die Q-Learning Methode

Q-Learning wurde bereits in der Einleitung als Reinforcement Learning Methode eingeordnet, die in der Lage ist, selbständig ohne Dateneingabe zu lernen. Das Q steht für Quality, denn in diesem Verfahren geht es darum qualitativ hochwertige Entscheidungen für jede denkbare Situation innerhalb eines Problems zu finden (Klein, 2021, S. 543). Es werden mit Codezeilen Umgebungen modelliert, beispielsweise Videospiele oder Märkte, worin der *Agent* am Ende übermenschlich, qualitativ hochwertige Entscheidungen finden soll. Wie alle Reinforcement Learning Algorithmen wird aus den Ergebnissen der Erfahrung/Vergangenheit gelernt und optimiert, um die optimale Policy zu finden. Der erste Anwender von Q-Learning war Watkins (1989), welcher Markov Entscheidungen modellierte. Für eine Markov Entscheidung gilt für jede Periode $\mathrm{t} = 1, 2, 3 \ldots$ eine Beobachtung vom Zustand (*state*) $\mathrm{s}_t \in \mathrm{S}$, nach der der *Agent* die Strategie (*action*) $\mathrm{a}_t \in \mathrm{A}(\mathrm{s_t})$ wählt. Beides seien endlich ausgeprägte Variablen. Die Ausgangssituation in der die Gegenspieler, anderen Algorithmen ihre Entscheidung, in diesem Fall der Preis, gesetzt haben wird als *state* beobachtet und mit der *action* eines Konterpreises geantwortet. Für jedes s_t und gewählte a_t gibt es daraufhin einen bestimmten Gewinn π_t. Nach diesem Mechanismus wiederholt geht es weiter zur nächsten Ausgangssituation, dem *state* s_{t+1}. Dabei gilt die Funktion $\mathrm{F}(\pi_t, \mathrm{s}_t \,|\mathrm{s}_t, \mathrm{a}_t)$, welche die Wahrscheinlichkeitsverteilung der Gewinne bestimmt. Der *Agent* verfolgt die Maximierung des erwarteten Gewinns mit der Formel 1, wobei die Summe der Gewinne mit dem Diskontierungsfaktor $\delta^t < 0$ multipliziert wird (Klein, 2021, S. 543).

Formel 1 Erwartungswert aller Gewinne

$$E[\sum_{t=0}^{\infty} \delta^t \ \pi_t]$$

Die Q-Funktion beseht aus dem Optimalitätsprinzip von Richard Bellman, welches ein gängiges Prinzip für Optimalitätsprobleme in der Programmierung ist. Die Gleichung besagt, dass ein Problem aus optimalen Teillösungen (Entscheidungsabfolgen nach der Ausgangssituation) zusammengesetzt werden kann. Entsprechend folgt die Q-Funktion in welche für jedes s und a die optimalen Strategien für jede Ausgangssituation in der Matrix $|\mathrm{S}|\mathrm{x}|\mathrm{A}|$ angibt (Klein, 2021, S. 543).

Formel 2 Q-Funktion

$$Q(s,a) = E(\pi \ \mid s,a) + \ \delta \, E[\max_{a' \in A} \ Q(s',a') \mid s,a]$$

Die erste Q-Matrix Q_0 startet mit willkürlichen Werten. In der ersten Preissetzungsrunde wird ein a_1 für das jeweilige s_1 gewählt, das resultierende π_1 sowie s_{t+1} beobachtet. Basierend

darauf wird die entsprechende Zelle in der der Matrix $Q_1(s, a)$ entsprechend Formel 3 aktualisiert angibt (Klein, 2021, S. 543).

Formel 3 Q-Learning Funktion

$$Q_{t+1}(s,a) = (1 - \alpha)Q_t(s,a) + \alpha[\pi_t + \delta \max_{a \in A} Q_t(s', a')]$$

Nach Formel 3 berechnet sich der neue Wert der Zelle aus einer Verknüpfung von dem Preis aus der vorherigen Phase $t - 1$ und dem aktuellen Gewinn, addiert mit dem diskontierten Wert für die nächste Situation, wobei $\alpha \in [0,1]$ ist und die Lernrate bestimmt angibt (Klein, 2021, S. 543). Q-Learning liegt die Idee von willkürlichem Experimentieren (*Exploration*) und Verwendung gewinnmaximierender Q-Werte (*Exploitation*) zu Grunde. Diese werden in gemischten Strategien gespielt. Zum Lernen, welches Preissetzungsverhalten optimal ist werden willkürlich Preise ausprobiert, um die Reaktionen des Gegners zu beobachten. Dadurch werden irgendwann alle Zellen der Matrix aktualisiert sein und das Gelernte kann bei der *Exploitation* angewandt werden. Es kostet Zeit, die gesamte Matrix durchzugehen. Das Lernen und Sammeln von Information muss gegenüber den Kosten von Zeit sowie Hardwarekapazitäten abgewogen werden. Als *Exploration* Strategie schlagen Calvano et al. (2020) das ε-Greedy Modell vor, welches allgemein bekannt im Reinforcement Learning ist. Hierbei wird in gemischten Strategien mit einer Wahrscheinlichkeit von ε eine willkürliche Wahl der Strategie a und mit der Wahrscheinlichkeit $1 - \varepsilon$ der Q-Value gespielt. Mit dieser Gewichtung wird zwischen den beiden Modi gewechselt. Um das System nun auf wiederholende Spiele anzuwenden, wird die Antwort des gegnerischen Algorithmus als weitere Variable aufgenommen. In dem Fall die Preisantworten der anderen Firmen. Mit dem hinzufügen der gegnerischen Aktion erweitert die Auswahl an Zuständen S merkbar, bis es zu einem Problem wird. Damit S nicht zu groß wird kann die Erinnerung des Algorithmus begrenzt werden. Der *Agent* kann sich durch diese Annahme nur noch an die k letzten Zustände erinnern und löscht die vorherigen Werte. Dadurch, dass mehrere Spieler wiederholt Spielen kann es sein, dass es zu keinem Gleichgewicht kommen kann, also beispielsweise nie ein Nash-Gleichgewicht oder zu einem Preis bei Kollusion. Dazu kommt es, wenn die Algorithmen auf Basis ihrer Erfahrung ihre Strategien wechseln. Wenn ein Spieler nun seine Strategie ändert, können die anderen auch mit einem Strategiewechsel unerwartete Preise setzten, woraufhin sich kein Gleichgewicht findet angibt (Klein, 2021, S. 543).

3. Methode und Ergebnisse bei Calvano et al. (2020)

In dem Experiment wird ein Bertrandt Preiswettbewerb im Oligopol in 1000 Runden pro Experiment untersucht. Innerhalb des wirtschaftlichen Umfelds eines Kollusionsmodells, dem wiederholenden Preiswettbewerb, mit simultaner Preissetzung. Alle Entscheidungen werden zunächst willkürlich getroffen und beruhen im Verlauf der Durchläufe auf den Erfahrungen in vergangenen Runden, also den aktualisierten Zellen der Q-Matrix, genau wie zuvor beschrieben. Es wird eine logit Nachfrage angenommen, sowie konstante Grenzkosten, weil es realitätsnah sei und eine repräsentative Annäherung. n ist die Anzahl der Firmen. Formel 4 gibt die Nachfrage in Periode t für das Produkt $\mathrm{i} = 1,2,3,\ldots,\mathrm{n}$ an.

Formel 4 Nachfrage nach Gut i

$$q_{i,t} = \frac{e^{\frac{a_i - p_{i,t}}{\mu}}}{\sum_{j=1}^{n} e^{\frac{a_i - p_{i,t}}{\mu}} + e^{\frac{a_0}{\mu}}}$$

Wobei a ein Produkt Qualitätsindex zur vertikalen Differenzierung ist. μ ist ein Parameter für die horizontale Differenzierung. Konvergiert μ gegen 0 dann bedeutet die perfekte Substituierbarkeit. Der Gewinn berechnet sich nach Formel 5.

Formel 5 Gewinn der Firma i zum Zeitpunkt t

$$\pi_{i,t} = \left(\mathrm{p}_{i,t} - \mathrm{c}_i\right)\mathrm{q}_{i,t}$$

c sind dabei die Grenzkosten und Fixkosten werden vernachlässigt. Preise können nur in dem Intervall $[\mathrm{p}^N - \xi(\mathrm{p}^M - \mathrm{p}^N), \mathrm{p}^M + \xi(\mathrm{p}^M - \mathrm{p}^N)]$ gesetzt werden. p^N bezeichnet den Preis im Bertrand Nash Gleichgewicht, p^M den Preis im Monopol und ξ < 0 ist ein Faktor, welcher verhindert, dass die Spieler genau p^M und p^N wählen. Es können Preise oberhalb des Monopolniveaus und unterhalb des Bertrand Preises gesetzt werden. Die begrenzte Erinnerung besteht aus den Preisen der letzten k Perioden, wie in Formel 5 gezeigt. Mit dem ε-Greedy Modell wird die *Exploitation* und *Exploration* bestimmt. Formel 6 ist so aufgebaut, dass das willkürliche Preissetzten mit der wachsenden Anzahl an Perioden abnimmt, da $\beta > 0$.

Formel 6 ε-Greedy Modell

$$\varepsilon_t = e^{-\beta t}$$

Das Baselinemodel ist ein symmetrischer Duopol mit $n = 2,\ c_i = 1,\ a_i - c_i = 1,\ a_0 = 0,\ \mu = \frac{1}{4}$, $\delta = 0{,}95,\ m = 15,\ \xi = 0{,}1$ und $k = 1$. Die Preis Kostenspanne im Bertrand Wettbewerb beträgt

ca. 47 % und in der perfekten Kollusion 94 %, für Q_0 gilt Formel 7 mit der Annahme, dass zuerst die Preissetzung vollkommen willkürlich gewählt wird.

Formel 7 Q_0 - Matrix

$$Q_{i,0}(s, a_i) = \frac{\sum_{a-i \in A^{n-1}} \pi_i(a_i, a_{-i})}{(1-\delta)|A|^{n-1}}$$

Die Autoren gingen der Frage nach, ob Preissetzungsalgorithmen autonom Kollusion lernen würden. Das Ergebnis ist, dass einfache Algorithmen lernen Preise zu setzten, die unter Monopolpreisen und über statischem BPW Ergebnis lägen. Das, ohne miteinander zu kommunizieren, die Umgebung zu kennen oder explizit darauf programmiert zu sein. Es entstanden kollusive Strategien, durch *Trail and Error,* mit zeitlich endlichen Abstrafungsphasen, wobei nach diesen Preissenkungen meistens eine Konvergenz zum vorherigen Preis bei Kollusion zu finden war. Das bedeutet, wenn das Experiment repräsentativ für alle auf den Märkten verwendeten Algorithmen herangezogen werden kann, dass es zu Kollusiven Verhalten und einem Wohlfahrtsverlust kommt, wenn diese vermehrt eingesetzt werden.

	Sessions by cycle length						Nash equilibria
	1-Sym.	1-Asym.	1	2	≥3	All	
Frequency	0.277	0.366	0.643	0.238	0.119	1	0.505
Average profit gain	0.866	0.855	0.860	0.846	0.793	0.849	0.854
Standard deviation profit gain	0.115	0.114	0.114	0.104	0.097	0.112	0.108
Frequency of Nash equilibria	0.686	0.661	0.672	0.294	0.025	0.505	1.000
Average Q-loss (on path)	0.001	0.001	0.001	0.002	0.004	0.002	0.000
Standard deviation Q-loss (on path)	0.002	0.004	0.003	0.003	0.006	0.004	0.000
Average Q-loss (all states)	0.018	0.018	0.018	0.018	0.018	0.018	0.018
Standard deviation Q-loss (all states)	0.006	0.007	0.006	0.006	0.006	0.006	0.006

Abbildung 2 Deskriptive Statistiken, Quelle: Calvano et al. (2020), S. 3277

Abbildung 2 zeigt die Deskriptiven Statistiken des Baslinemodells. Jeweils die Häufigkeit, Durchschnittliche Profitaufschlag, Anzahl der Nash-Gleichgewichte und *Q-loss* Werte. *Cycle length* bezieht sich auf die Preissetzungsrunden, wo jeweils symmetrische und asymmetrische Preissetzungen entstehen können. In der ersten Zeile werden dafür die Häufigkeiten angegeben. Symmetrische Preissetzung impliziert eine Trigger Strategie. Das kommt in ca. einem Drittel aller Durchgänge vor. Dabei werden Durchschnittliche 86,6% gesetzt, was fast eine Preiserhöhung um das Doppelte darstellt. In 68,6 % sind diese Runden auch Nash-Gleichgewichte. Asymmetrische Preissetzungen kommen in 36% der Runden vor. In ca. der Hälfte aller Versuche konvergierten die Ergebnisse in einem Nash Gleichgewicht.

Eine weitere Erkenntnis ist, dass bei steigender Anzahl an Mitspielern bzw. Firmen, die Preise setzten, der Grad an Kollusion sinke, wobei die optimale Anzahl an Spielern bei 3 oder 4 läge, was dann maximale Kollusion erzeuge. Es wurde eine leichte, positive Korrelation von dem durchschnittlichen Preisaufschlag und dem optimalem Gleichgewichtsergebnis mit einem Pearsons Koeffizient von 0,12 gefunden. Es wird immer ein höherer Preis über dem Wettbewerbsniveau als Strategie gespielt. Wie hoch der durchschnittliche Preisaufschlag ist, ergibt sich durch die Differenz des durchschnittlichen Profites der jeweiligen Firma mit dem Preis im Bertrand Nash-Gleichgewicht pro Differenz aus Monopol und Bertrand Nash-Gleichgewichtspreis. Ist das Ergebnis 0, so entspricht der Preis dem Wettbewerbswert. Ist der durchschnittliche Preisaufschlag gleich 1 im Fall von Kollusion. Das Ergebnis ist, dass die Preise meistens über dem Bertrandt Nash Gleichgewicht im *One-Shot Game* und selten über dem Monopol Preis. Am höchsten sei der durchschnittliche Preisaufschlag bei niedrigen α und β. Bei Spielen mit mehreren Spielern ist es nicht garantiert, dass es ein optimales Gleichgewicht gibt. Das Ergebnis, gegen das die Entscheidungen am Ende konvergieren, ist möglicherweise nicht das Optimum. Wenn $k = 0$, dann ist keine Kollusion möglich, weil die Algorithmen nicht Kooperatives Verhalten bestrafen können, da sie sich nicht daran erinnern können. Wenn δ = 0 ist ebenfalls keine Kollusion möglich, weil die Diskontierung nicht stattfindet, sind die Algorithmen zu kurzsichtig programmiert. Sie sehen nur die nächste Auszahlung und die Folgeauszahlungen stiften keinen Nutzen, weswegen in den nächsten Runden auch keine Bestrafung nützen kann. Der durchschnittliche Profitaufschlag variiert also mit δ. Ist das δ sehr gering fällt der durchschnittliche Profitaufschlag gering aus. Von dem Ausgangspunkt sinkt der Aufschlag mit steigendem δ leicht ab, bevor es ansteigt. Asymmetrie hindere Kollusion, verringern Profite, da die Firmen auf einmal ein zweiseitiges Problem zu lösen haben. Sie müssen das Preise ohne Kommunikation koordinieren. Nachfrageschocks mindern Kollusion aber verhindern diese nicht. Schließlich ist ein weiteres Ergebnis, dass die größte Hinderung an Kollusion variierende Marktstrukturen sei, weil die neue Firma noch nicht Erfahrung gesammelt hat. Der durchschnittliche Profitzuwachs sinke in diesem Experiment um 60%. Das optimale Gleichgewicht in weniger als 10%, Abstrafungen fallen relativ milder aus und Abweichung lohn sich mehr.

4. Q-Learning als repräsentativer Beweis für Kollusion

Nachdem die Forschung von Calvano et al. (2020) vorgestellt wurde, wird im Folgenden abgewogen inwiefern Q-Learning überhaupt als Repräsentant für *Dynamic Pricing* herangezogen werden kann, um auf eine Kollusion aller Typen von Algorithmen zu schließen. Wenn das nicht der Fall ist kann nicht auf einen Wohlfahrtsverlust durch Preissetzungsalgorithmen geschlossen werden. Es kämen in dem letzten Jahrzehnt immer mehr *Dynamic Pricing* in Einsatz, dank des Fortschritts in der Entwicklung von *rule-based* zu Reinforcement Learning Programmen und dem gleichzeitigen Wachstum von online Märkten sowie des Zuwachses an verfügbaren Daten über andere Märkte und Produkte, wie beispielsweise Öl und Benzin. Kollusion ließe sich schwer allein an Marktpreisen erkennen, weshalb eine experimentelle Herangehensweise gewählt wurde, in der man die Algorithmen selbst entwarf und untersuchte, statt sich ausschließlich an Marktergebnissen zu orientieren, wie beispielsweise Chen (2016) es probierten. Die konstruierten Preissetzungsagenten interagieren in dem Experiment in einem computersimulierten Marktplatz mit erfundenen Preisen, vollkommen transparent für die Forscher. Eine zentrale Herausforderung liegt darin ein repräsentatives wirtschaftliches Umfeld und Algorithmen zu schaffen, die die Realität simulieren können. Denn Firmen veröffentlichen ihre Algorithmen nicht. Das bedeutet die Forscher nehmen nur an, dass solche Methoden tatsächlich angewendet werden. Die gewählte Q-Learning Methode habe den Nachteil von langsam arbeitenden Algorithmen. Durch den Fokus auf Lernen mit Erkundung, Exploration, käme es zu Problemen bezüglich der Zeit, die benötigt wird, um die Preise zu setzten. Das gibt erste Gründe, um an der Umsetzung der Methode in der Realität zu zweifeln. Andererseits spricht für das Verfahren, dass es durch einen einfachen Aufbau, wenige Parameter die Willkür minimiere und Reinforcement Learning in den meisten Fällen jeglicher Anwendungsprobleme übermenschliche Ergebnisse produziert.

Es gibt, neben Q-Learning, weitere Methoden der Computer Science für die Lösung von solchen Problemen. Beispielsweise OLS Schätzverfahren mit Machine Learning, die Random Forrest Methode oder Bayessche Strategien zur Preissetzung sowie Kombinationen der Methoden miteinander (Dilmegani, 2022). Calvano et al. (2020) nehmen an, dass Q-Learning eine verbreitete Methode sei, aber nennen keine Grundlage für diese Annahme, sondern verweisen darauf, dass es unter Computer Scientist populär sei, jedoch ohne Quelle (Calvano, Calzolari, & Denicoló, 2020, S. 3270). Damit sind die Autoren nicht allein. Beispielsweise Itto und Petit (2017) nehmen ebenfalls an, dass in einigen Sektoren Q-Learning verbreitet sei und schießen deshalb induktiv auf alle anderen Algorithmen (Itto & Petit, 2017, S. 6). Jedoch kann nicht mit fehlende Information über die tatsächliche Anwendung von Algorithmen auf die Grundgesamtheit geschlossen werden ohne belastbare Gründe oder Beweise zu nennen, denn das wäre keine wissenschaftlich belastbare Methode. Die Autoren betonen wiederholt

das sie von „*behavior of algorithms powerde by Artificial Intelligence*“ (Calvano, Calzolari, & Denicoló, 2020, S. 3267) sprechen und dabei wird aber nur Q-Learning untersucht. Das ist problematisch, wenn es noch andere algorithmische Methoden in der Praxis der Preissetzung gibt und keine Informationen, welche auf den Märkten angewendet werden. Denn unter Umständen führen andere Algorithmen zu anderen Ergebnissen. Unter anderem spricht dieses Problem Klein (2021) in der Forschung zum selben Thema an. Er bezeichnet es als unwahrscheinlich, dass in der realen Welt nur Q-Learning verwendet, wird aufgrund der Limitationen der Methode (Klein, 2021, S. 539). Chen et al. (2016) richtet die gesamte Untersuchung von Algorithmen in Amazon auf der Unwissenheit über die tatsächlich angewandten Taktiken aus. Statt herauszufinden welche Algorithmen welche Wirkungen wird geguckt welche Anbieter *Dynamic Pricing* anwenden und welchen Effekt das hat, ohne von einer speziellen Methode auszugehen (Chen, Mislove, & Wilson, 2016) .

Trotz dieser Ungewissheit ist Q-Learning in der Literatur über Kollusion von AI Algorithmen am häufigsten vertreten und dadurch in der Computer Science am weitesten erforscht (Calvano, Calzolari, & Denicoló, 2020, S. 3268; Klein, 2021; Dilmegani, 2022; Itto & Petit, 2017; Cheng, 2009; Lu, Ho, Hong, & Zhang, 2018; Raju, Narahari, & Ravikumar, 2003). Das macht es wahrscheinlicher, dass es in der Praxis häufig angewendet wird. Darüber hinaus spricht auch die Einfachheit und Vielfalt von Q-Learning für den Gebrauch auf den Märkten (Calvano, Calzolari, & Denicoló, 2020, S. 3270; Itto & Petit, 2017, S. 6). Durch die wenigen Parametern wird die Willkür und Gefahr von verzerrten Ergebnissen reduziert. Wenn ein so einfaches Modell schon Kollusion erzeugen kann, dann können es komplexere auch, so die Annahme von Calvano et al. (2020), Klein (2021) und weiteren Forschenden. Hinzukommen die jeweiligen Robustheitschecks, die das Beweisen. Dem Aspekt, dass es noch andere Methoden gibt, kann entgegengesetzt werden, dass den Algorithmen trotzdem sehr wahrscheinlich Gewinnmaximierung zu Grunde liegt. Die Parameter werden unter ähnlichen Annahmen auf unterschiedliche Weise maximiert (Cope, 2007, S. 270; Gu, 2022). An dieser Stelle wird nicht detaillierter auf den Vergleich von Methoden eingegangen, weil der Fokus dieser Arbeit auf das Q-Learning gelegt wurde.

Auf Grund der fehlenden Information über die tatsächlich verwendeten Algorithmen auf den Märkten kann noch nicht zweifelsfrei auf einen Wohlfahrtsverlust durch Kollusion geschlossen werden. Deshalb ist es notwendig die Forschung in die Richtung auszubreiten und voranzutreiben, um Konsumenten vor Preisaufschlägen zu bewahren.

5. Fazit

Algorithmen sind ein Teil des modernen Lebens geworden und beeinflussen unseren Alltag. Es ist eine Aufgabe der Wissenschaft negative Einflüsse rechtzeitig zu erforschen, bevor die Gesellschaft Schaden nimmt. Daran arbeitet die Forschung im Bereich des *Dynamic Pricing* durch KI. Es ist von zahlreichen Wissenschaftlern bestätigt worden, dass es Tendenzen zur Kollusion bei der Preissetzung von Algorithmen gibt, was zu einem Wohlfahrtsverlust führt und Verbraucher dazu drängt mehr für Produkte auszugeben als nötig. Calvano et al. (2020) haben mit ihrer experimentellen Herangehensweise bewiesen, dass selbst simple Q-Learning Algorithmen mehrheitlich zu kollusiven Markergebnissen kommen. Diese Erkenntnis teilen auch andere Forscher. Es wurde diskutiert inwiefern denn das Ergebnis auf alle, in der realen Welt, angewandten Methoden von *Dynamic Pricing* verallgemeinert werden können. Andere Methoden müssen nicht zwangsläufig zu denselben Marktergebnissen führen oder sind bis heute nicht stark genug erforscht worden. Außerdem ist unklar welche Methoden genau von Firmen verwendet werden. Deswegen bleibt nichts anderes übrig als darauf zu schließen, dass wenn Q-Learning populär und erforscht in der Computer Science ist, es auch Anwendung im Privatem Sektor bei der Preissetzung findet oder dass ähnliche Methoden mit denselben Annahmen zu ähnlichen Ergebnissen kommen. Am Ende ist dennoch unklar, inwiefern Q-Learning Algorithmen repräsentativ für alle Methoden von *Dynamic Pricing* herangezogen werden können oder nicht. Das macht es den Gesetzgebern und dem Kartellamt schwer zu regulieren und das Problem kann so lange nicht gelöst werden. Im Folgenden werden Vorschläge und Möglichkeiten für eine Forschung skizziert, welche helfen könnten genannte Probleme aus dem Weg zu räumen.

Erstmal sollte nicht nur ein Markt betrachtet werden, sondern möglichst viele auf denen *Algorithmic Pricing* angewendet wird. Hierfür könnten Beraterfirmen, die solche Software anbieten befragt werden. Berater sind in der Regel gut informiert über die aktuelle Lage und haben echte Erfahrungen direkt aus der Praxis. Dabei ist darauf zu achten, dass die jeweiligen Beratungsunternehmen breit gefächerte Sektoren als Kunden haben, damit untersucht werden kann, ob kollusive Tendenzen auch verallgemeinerbar unabhängig vom Markt gelten. Vielleicht ist es nötig Listen von Beratungsunternehmen zu erstellen für jeweils jeden Sektor und daraus eine Zufallsstichprobe zu ziehen. Alternativ beschränkt man sich nur die ein oder zwei Sektoren in denen das *Dynamic Pricing* populär ist. Nach der Auswahl der Beratungsfirmen werden deren Experten umfangreich befragt, welche Art von Algorithmen in welchen Sektoren tatsächlich angewandt werden. In einem nächsten Schritt werden diese Methoden genau untersucht und modelliert, ähnlich wie bei Calvano et al (2020) wird dann anhand von simplen Versionen der Algorithmen erforscht, ob es zur Kollusion kommt oder nicht. Danach

könnte man noch wie Chen et al. (2016) anhand von echten Markergebnissen die kausalen Effekte von Algorithmic Pricing identivizieren.

Aus dieser Arbeit kann man mitnehmen, dass Algorithmen in der Lage sind Aufgaben auf übermenschlichen Nivau zu lösen und effizientere Ergebnisse produzieren als jeder Experte es könnte. Nicht nur im Spiel Go, bei Computerspielen, im Trading, sondern auch beim festlegen von Preisen. Dabei wird nicht nur das ergebniss ökonomisch Effizient, es wird auch das zentrale Problem des gefnagennen Dilemmas gelöst, weil menschliche Eigenschaften nicht mehr die Kooperation behindern. Die Fähigkeit riesiege Datenmengen zu verarbeiten und für jede einzelne Runde die mathematisch korrekt diskontierten und gegebenenfalls abgestraften Entscheidung zu treffen macht die Algorithmen superior gegnüber jedem Menschen.

Literaturverzeichnis

Abhari, R., Arnold, G. W., Canavero, F., Goldof, D., Haemmerli, B.-M., Jacobson, D., . . . Zobrist, G. (2012). *Reinforcement and Systemic Machine Learning for Decision Making.* IEEE Press.

Bofinger, P. (2020). *Grundzüge der Volkswirtschaftslehre - Eine Einführung in die Wissenschaft von Märkten.* Pearson.

Bundesmisterium der Justitz. (31. 05 2022). *Gesetze im Internet*. Von Gesetz gegen Wettbewerbsbeschränkungen (GWB) § 1 Verbot wettbewerbsbeschränkender Vereinbarungen: https://www.gesetze-im-internet.de/gwb/__1.html abgerufen

Calvano, E., Calzolari, G., & Denicoló, V. (2020). Artifical Intelligence, Algorithmic Pricing, and Collusion. *American Economic Review* , S. 3267-3297.

Chen, L., Mislove, A., & Wilson, C. (2016). *An Emperical Analysis ofAlgorithmic Pricing on Amazon Marketplace.* International World Wide Web Committee.

Cheng, Y. (2009). Real Time Demand Learning-Based Q-learning Approach for Dynamic Pricing in E-retailing Setting. *International Symposium on Information Engineering and Electronic Commerce*, 594-598.

Cope, E. (2007). Bayesian Strategies for Dynamic Pricing in E-Commerce. *Naval Research Logistics*, 265-281.

Dilmegani, C. (11. 06 2022). *Dynamic Pricing Algorithms: Top 3 Models in 2022*. Von research.aimultiple.com: https://research.aimultiple.com/dynamic-pricing-algorithm/ abgerufen

Egli, C. (27. 05 2022). *Das Gefangenendilemma.* Von http://christop.egli.home.hefr.ch/Dreamweaver/Gefangendilemma_L.pdf abgerufen

Engelkamp, P., Sell, F. L., & Sauer, B. (2020). *Einführung in die Volkswirtschaftslehre.* Springer Gabler.

Gu, Y. Y. (11. 06 2022). *About covid19-projections.com*. Von https://covid19-projections.com/: https://covid19-projections.com/about/ abgerufen

Itto, A., & Petit, N. (2017). *Algorithmic Pricing Agents and Tactic Collusion: A Technological Perspective.*

Klein, T. (2021). Autonomous algorithmic collusion: Q-learning under sequential pricing. *RAND Journal of Economics*, S. 538-599.

Lu, R., Ho, S., Hong, & Zhang, X. (2018). A Dynamic pricing demand response algorithm for smart grid: Reinforcement learning approach. *Applied Energy*, 220-230.

Raju, C., Narahari, Y., & Ravikumar, K. (2003). Reinforcement learning applications in dynamic pricing of retail markets. *EEE International Conference on E-Commerce*, 339-346.

Eidesstaatliche Erklärung

Ich erkläre, dass ich die vorliegende Hausarbeit selbstständig verfasst habe Diplomarbeit mit dem Titel „Algorithmen im Preiswettbewerb - Inwiefern können Q-Learning Algorithmen repräsentativ für alle Methoden von Dynamic Pricing herangezogen werden?“. Ich habe keine anderen als die angegebenen Quellen oder Ressourcen verwendet und ich haben alle Materialien, die wörtlich oder inhaltlich vom Verwendeten zitiert wurden, ausdrücklich gekennzeichnet Quellen. Diese Arbeit wurde weder ganz noch teilweise an diesem oder einem anderen Universität eingereicht.

Name: Tsymboulova
Vorname: Anastasia
Matrikel-Nummer: 804385
Studiengang: Politik und Wirtschaft
Thema der Arbeit: Algorithmen im Preiswettbewerb - Inwiefern können Q-Learning Algorithmen repräsentativ für alle Methoden von Dynamic Pricing herangezogen werden?
Unterschrift: