Universität Potsdam

Wirtschafts- und Sozialwissenschaftliche Fakultät

Professur für Politik und Regieren in Deutschland

Machine Learning Prozesse im Policy Cycle am Beispiel von covid19-projections.com – Eine Untersuchung der Reliabilität, Validität und Objektivität der Projektionen

Inwieweit erfüllen Projektionen von Machine Learning Prozessen die Gütekriterien der quantitativen Forschung?

Hausarbeit

[BVMPUV210] Vertiefungsmodul Politik und Regieren in Deutschland und Europa
421811 Seminar: Algorithmic Governance im Policy Cycle
Sommersemester 2021
Lehrstuhlinhaber: Prof. Dr. Julia Fleischer
Tutor: Camilla Wanckel

vorgelegt von:
Anastasia Tsymboulova (804385)
Politik und Wirtschaft (4. Fachsemester)
tsymboulova@uni-potsdam.de
Nelly-Sach-Str. 3
14480 Potsdam
0331/712415

Abgabedatum: 01.10.2021

Inhaltsverzeichnis

Inhaltsverzeichnis I

Abbildungsverzeichnis II

1. Einleitung 1

2. Begriffe und Grundlagen 1

2.1 Machine Learning 1

2.2 Politikformulierung 2

2.3 Gütekriterien 5

2.3.1 Objektivität 6

2.3.2 Reliabilität 7

2.3.3 Validität 7

3. Methode 8

3.1 Fallauswahl 8

3.2 Modell von covid19-projections.com 8

3.3 Vorgehen 11

4. Analyse 12

4.1 Objektivität 12

4.2 Reliabilität 13

4.3 Validität 13

5. Fazit 15

Literaturverzeichnis III

Eidesstaatliche Erklärung V

Abbildungsverzeichnis

Abbildung 1 Der idealtypische Policy Cycle, Quelle: Jann & Wegrich, 2008, S. 86 3
Abbildung 2 Überarbeiteter Policy Cycle, Quelle: Höchtel et al., 2016, S 163 5
Abbildung 3 Modellaufbau covid19-projections, Quelle: covid19-projections.com 9
Abbildung 4 Vergleich von Covid-19 Schätzmodellen, Quelle: https://covid19-projections.com/about/#historical-performance 14

1. Einleitung

Die Covid19 Pandemie sorgte 2020 für eine weltweite Krise, die es in einem solchen Ausmaß noch nicht gegeben hat. Das Virus breitete sich unkontrollierbar aus und Politiker der gesamten Welt mussten, unter der Verantwortung des Lebens ihrer Bürger, risikoreiche Entscheidungen treffen, welche über den weiteren Verlauf der Pandemie entscheiden würden. Das waren Beschlüsse über Maßnahmen zur Eindämmung, wie beispielsweise Allokation von Ressourcen, wie Sauerstoffversorgungen, Masken oder Krankenhausbetten. Diese wichtigen Entscheidungen wurden mit Ungewissheit getroffen, ob sie wirklich zielführend sind und, ob unter Anbetracht der zukünftigen Entwicklungen, diese auch gerechtfertigt sind. In der Pandemie wurden viele wissenschaftliche Erkenntnisse über das Virus, sowie über die Maßnahmen als eine Entscheidungsgrundlage verwendet, um alle Beschlüsse legitim umsetzen zu können. Im Zuge des wissenschaftlichen Fortschrittes entwickelte sich eine neue Methode zur Folgeabschätzung zukünftiger Verläufe von beispielsweise Todes- oder Infektionszahlen. Eine dieser Methoden, die in der Politikformulierung unterstützend herangezogen wurde, ist das Projekt von Youyang Gu, bekannt unter dem Titel der Website covid19-projections.com. In dieser Arbeit wird gezeigt wie Machine Learning Prozesse im Policy Cycle am Beispiel von covid19-projections.com zur Bekämpfung der Pandemie beigetragen haben und untersucht inwieweit die Projektionen die Gütekriterien der quantitativen Forschung erfüllen. Außerdem wird beantwortet inwieweit erfüllen Projektionen von Machine Learning Prozessen die Gütekriterien der quantitativen Forschung? Dafür wird zuerst ein theoretischer Überblick über die Konzepte von Machine Learning, Politikformulierung im Policy Cycle und die Gütekriterien gegeben. Darauf folgt die Begründung der Fallauswahl und eine Vorstellung des Projekts, um danach die Gütekriterien an den Projektionen zu überprüfen. Schließlich wird ein Fazit aus den Ergebnissen gezogen, sowie ein Ausblick gegeben. Eine These lautet, dass die Projektionen die Gütekriterien erfüllen, da es sich hier um eine sehr quantitative Methode handelt ohne viel Interpretationsspielraum, wie bei qualitativen Analysen von beispielsweise Fragebögen.

2. Begriffe und Grundlagen

Im Folgenden wird ein Überblick über das Themengebiet Machine Learning, dessen Entwicklung und den heutigen Stand gegeben, da es ein wichtiger Bestandteil des Fallbeispiels ist. Darauf folgt die Einordnung des Prozesses der Politikformulierung in den Politikwissenschaftlichen Kontext des Policy Cycles. Dabei wir die klassische Theorie und eine moderne, angepasste Version verglichen. Schließlich werden die Gütekriterien als theoretischer Rahmen der Analyse vorgestellt.

2.1 Machine Learning

Machine Learning ist eine Methode, die sich darin definiert Computer zum Lernen zu bringen (Alzubi, Nayyar, & Kumar, 2018) und verordnet sich als Unterkategorie der Künstlichen Intelligenz, kurz KI. Der Konsens über die Definition von KI ist in der Literatur noch nicht eindeutig zustande gekommen, jedoch sei man sich einig, dass es Technologien bezeichne, mit dem Ziel menschliche Intelligenz nachzuahmen (Wang, 2008). Thierer et al. formulierte die künstliche Intelligenz als ein Programm, dass in der Lage sei Operationen auf höherer Ebene durchzuführen (Thierer, O'Sullivan Castillo, & Russell, 2017). Die KI könne die Fähigkeiten eines Menschen nachahmen oder über diese hinaus operieren. Dieses Konzept ließe sich weiter in schwache und starke KI unterteilt (Thierer, O'Sullivan Castillo, & Russell, 2017).

Machine Learning ist ein Interdisziplinares Feld der KI, welches zahlreiche neue Möglichkeiten in Forschung und Industrie schafft (Alzubi, Nayyar, & Kumar, 2018). Tech Giganten wie Google, Elon Musk, Apple und Amazon bedienen sich des maschinellen Lernens zur Verbesserung ihrer Dienste. Beispielsweise um Handys und andere Produkte, wie Google Lens oder Apples Home Pod zu verbessern (Alzubi, Nayyar, & Kumar, 2018). Die Geschichte der Entwicklung des maschinellen Lernens begann 1950 als Alan Turning den *Turning Test* (Alzubi, Nayyar, & Kumar, 2018, S. 4) erfand. Dieser solle die Intelligenz eines Programms einschätzen können. Sei dieses in der Lage Menschen zu überzeugen sie kommunizieren mit einem anderen Menschen und nicht mit einer Maschine so sei der *Turning Test* bestanden und das Programm gilt als intelligent (Alzubi, Nayyar, & Kumar, 2018). In den darauffolgenden Jahrzehnten gab es weitere Meilensteine in der Forschung. Beispielsweise wurden 1958 von Frank Rosenblatt die Grundsteine für die Entwicklung künstlichen neuronalen Netzwerken gelegt, die jetzt ein weiterer Zweig der KI bilden (Alzubi, Nayyar, & Kumar, 2018). 2006 wurde von Geoffrey Hinton der Begriff „Deep Learning" als Unterkategorie des maschinellen Lernens eingeführt und beschreibt eine neue Art der Architektur von neuronalen Netzwerken mit mehreren Schichten, die jeweils auch lernen können (Alzubi, Nayyar, & Kumar, 2018). Ein weiterer sehr bedeutender Fortschritt kam im Jahr 2016. Es gelang Google mit GoogleAlphaGo einen professionellen Spieler in dem hoch komplexen Brettspiel „GO" zu schlagen. Die Herausforderung bestand darin 10^{170} (Schrittwieser, et al., 2020) mögliche

Spielkonstellationen zu berechnen und mit mehreren Schichten an neuronalen Netzwerken einzuschätzen. Dieser Sprung vom *Tuning Test* zu einem Programm, welches in der Lage ist, hoch komplexe Aufgaben, besser als Experten zu lösen, hat eine sehr große Bedeutung für die gesamte Gesellschaft und insbesondere für das Forschungsfeld Data Science. Im Anhang 1 werden die Schritte von Mashine Learning Prozessen erläutert und genauer beschrieben.

Diese Methoden können nicht nur in der Industrie für Produkte und Dienstleistungen verwendet werden, sondern auch in der Forschung und Beratung der Politik. Die neuen Möglichkeiten helfen bei der Erklärung von sonst schwer beobachtbaren Phänomenen, sowie bei der Evaluation von politischen Maßnahmen bzw. der Einschätzung zukünftiger Wirkungen von politischen Entscheidungen. Im Zuge der E-Governance Diskussion wird in Anbetracht gezogen vermehrt Algorithmen Entscheidungen im politischen Prozess zur Unterstützung heranzuziehen (Höchtel, Parycek, & Schöllhammer, 2016; Kamateri, et al., 2015). Mit „Electronic Government“ **Es ist eine ungültige Quelle angegeben.**, auch kurz E-Government bezeichnet, wird seit den 2000ern die Durchführung von Regieren und Verwalten auf elektronischem Wege bezeichnet. Dabei ginge es konkreter darum Prozesse zur Willensbildung, Entscheidungsfindung, Leistungserbringung unter der Nutzung von moderner Informationstechnik umzusetzen **Es ist eine ungültige Quelle angegeben.**

2.2 Politikformulierung

Die Politikformulierung ist ein Schritt im Teil des klassischen Policy Cycles (Jann & Wegrich, 2008). Diese Darstellung des Politikprozesses ist ein heuristischer Rahmen zur Orientierung und Einteilung des Vorgehens in der politischen Praxis von der Entstehung von Gesetzen bis zur Abschaffung. Diese Darstellung ist keine Verbindlichkeit für Politiker, sondern lediglich ein Überblick über eine Möglichkeit die einzelnen Phasen einzuteilen. Im politischen Alltag sind die einzelnen Schritte nicht unbedingt eindeutig voneinander zu trennen oder verlaufen gleichzeitig statt, wie in Abbildung 1 dargestellt, nacheinander (Jann & Wegrich, 2008).

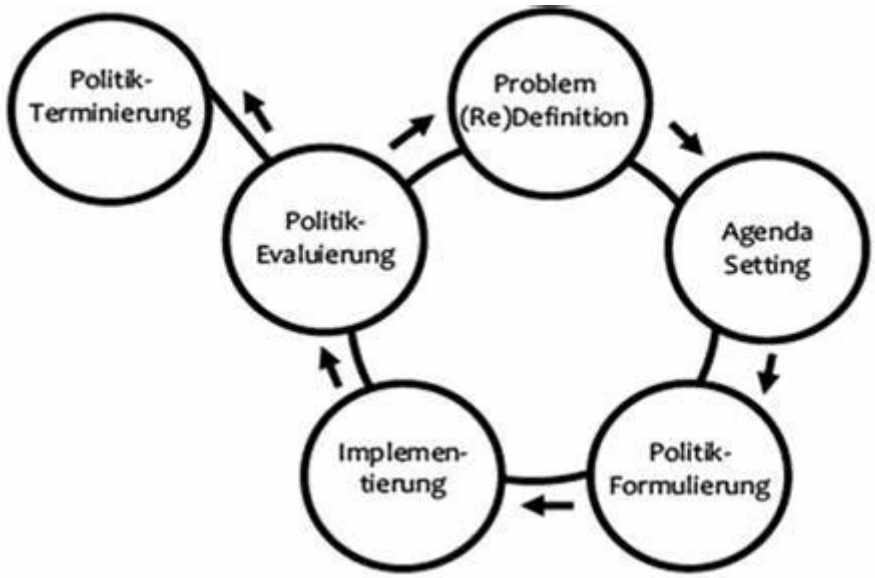

Abbildung 1 Der idealtypische Policy Cycle, Quelle: Jann & Wegrich, 2008, S. 86

Bevor der Policy Cycle erläutert werden kann, muss der Begriff Policy eingeordnet werden. Policy bezeichnet eine der drei Komponenten der Politik: Polity, Politics und Policy. Mit Polity sind die Institutionen und Regeln des politischen Systems zusammengefasst. Die Dimension Politics beschäftigt sich mit Akteuren und Wertvorstellungen, Interessen und daraus resultierende Konflikte und Machtkonstellationen zwischen den Akteuren. Während sich der Begriff Policy auf die inhaltliche Ebene von Gesetzen, Verordnungen, Programmen oder einzelnen Entscheidungen bezieht (Schneider & Janning, 2006). Diese inhaltliche Ebene wurde von Jann & Wegrich (2008) in die idealtypischen Schritte Problemdefinition, Agendasetting, Politikformulierung, Implementation, Politikevaluierung und Politikterminierung dargestellt (Jann & Wegrich, 2008). Die Problemdefinition beinhaltet das Erkennen eines gesellschaftlichen, sozialen Problems mit Steuerungsbedarf. (Jann & Wegrich, 2008). Danach wird im Schritt Agenda Setting dieses artikulierte Problem auf die politische Tagesordnung gebracht. Konkret wird die Agenda entweder öffentlich von Massenmedien, dem Fachpublikum oder von Regierung und Parlament wahrgenommen (Jann & Wegrich, 2008). Im Schritt der Politikformulierung geht es um die Ausarbeitung von Formulierungen von Handlungsalternativen und Zielen bis hin zu Gesetzen, Budgets, Verordnungen, Regierungserklärungen oder anderen Plänen. Geprägt durch Debatten seitens der Öffentlichkeit und allen anderen Stakeholdern, wie zuständige Verwaltungen, Ausschüsse oder Interessengruppen, ist die konkrete Formulierung ein vielseitiger Prozess (Jann & Wegrich, 2008). Die Regierung oder das Parlament trifft am Schluss dieser Diskussion die Entscheidung unter Vorbehalt aller Interessen, Meinungen, wissenschaftlichen Erkenntnissen, sowie ideologischer Ausrichtungen. Wichtige Einflüsse haben die verschiedenen Akteurskonstellationen und ihre Machtverteilung, die Dringlichkeit, politische Traditionen oder Strukturen innerhalb der Entscheidungsträger. Einzelne

Einflussfaktoren werden näher im Anhang 2 genannt. Nachdem die konkrete Politik formuliert wurde, kommt es zur Implementation dieser Beschlüsse. Das kann bedeuten, dass Interventionen getätigt, Ressourcen und Leistungen verteilt, Normen angewendet, Verträge unterzeichnet und Entscheidungen umgesetzt werden. Das passiert in der Regel durch die zuständigen Ministerien und Behörden. (Jann & Wegrich, 2008). In dem Schritt der Politikevaluierung wird untersucht, ob die formulierte Politik ihre gewünschte Wirkung und Auswirkungen entfaltet hat und eingeschätzt, ob zuvor definierte Ziele eingehalten wurden. Die Evaluationsforschung ist ein Teilgebiet der Policyforschung und stellt einen wichtigen Teil des Policy Prozesses dar. Auf Basis dieses Schrittes wird entschieden, ob es zu einer Reformulierung kommt und der Policy Cycle von vorne beginnt oder ob es zu einer Politikterminierung kommt. Die Evaluation wird von Jann & Wegrich (2008) eingeteilt in die administrative Bewertung durch die Ressorts und in die politische Bewertung von Akteuren im politischen System, eingeschlossen der Öffentlichkeit. Verwendet werden wissenschaftliche Studien, Regierungsberichte, die öffentliche Debatte, die Kontrolle der Verwaltung durch Gerichte, Rechnungshöfe oder anderen Mitteln der parlamentarischen Kontrolle (Jann & Wegrich, 2008).

Höchtel et al. (2016) stellt im Kontext der modernen Regierung einen neuen Policy Cycle auf. Unter der Annahme, dass mit dem technologischen Fortschritt die Möglichkeit einer Echtzeitverarbeitung von Daten ermöglicht wird, erweitert sich die Evaluierungsphase zu einem kontinuierlichen Prozess, der durch den gesamten Policy Cycle verläuft. Abbildung 2 zeigt den sogenannten e-Policy Cycle. Zu erkennen ist wieder ein Schritt, indem das Problem auf eine Agenda gesetzt wird, einen Schritt für die Implementation, einen für die Gestaltung der Politik, wie bei Jann & Wegrich (2008). Anders ist jedoch, dass die Schritte Policy Diskussion, Policy Akzeptanz und Bereitstellung der Mittel ergänz wurden. Diese werden jeweils kontinuierlich evaluiert, sobald die Daten bereitstehen, weswegen der Kreis nicht unidirektional verläuft, sondern immer wieder ein Schritt zurück gegangen werden kann. Diese neue, idealtypische Darstellung ergänzt den theoretischen Rahmen des Policy Cycles in der modernen Politik und verdeutlicht die Rolle von Big Data im Policy Prozess (Höchtel, Parycek, & Schöllhammer, 2016). Für die Zwecke dieser Arbeit wird der e-Policy Cycle als heuristischer Orientierungsrahmen herangezogen.

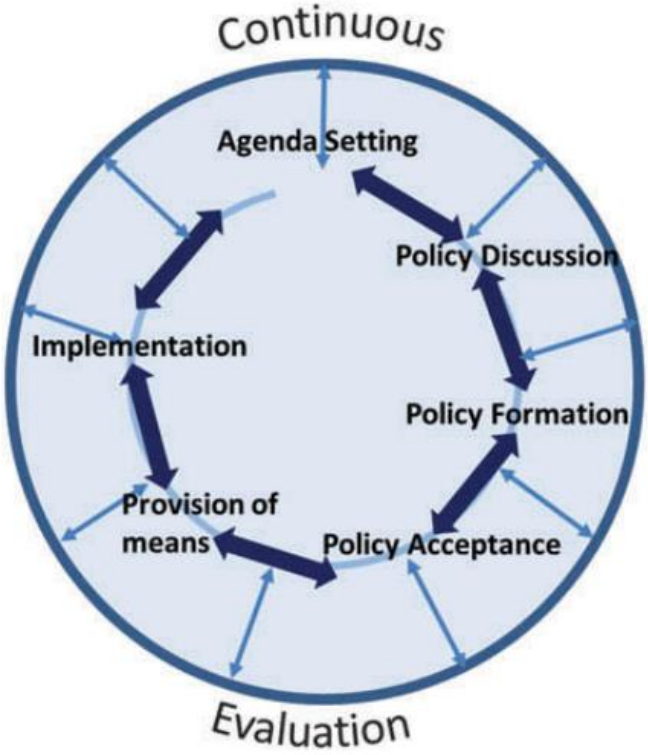

Abbildung 2 Überarbeiteter Policy Cycle, Quelle: Höchtel et al., 2016, S 163

Welche Rolle spielen nun Machine Learning Prozesse in dem e-Policy Cycle? Einerseits unterstützen Machine Learning Methoden die Bereitstellung von Informationen, Stimmungsanalyse, Simulation, Folgeabschätzung, Politikanalyse, Identifikation politischer Maßnahmen, zur Erkennung sozialer Muster und zur vorhersage (Kamateri, et al., 2015). Außerdem können Machine Learning Methoden bei der kontinuierlichen Evaluation eine Hilfe darstellen. So bieten diese Prozesse eine Unterstützung der Politikformulierung und Reformulierung.

2.3 Gütekriterien

Einen weiteren theoretischen Rahmen bilden die Gütekriterien der Forschung als ein Konzept zur Einschätzung der Qualität von Daten (Krebs & Menold, 2014). Um die wissenschaftliche Wertfreiheit zu wahren und subjektive Einflüsse so gering wie möglich zu halten, sowie erwarten zu können, dass die Resultate der Messung zuverlässig sind, werden die Kriterien Objektivität, Reliabilität, Validität formuliert. Krebs & Menold (2014) unterscheiden darüber hinaus in „Gütekriterien der Messinstrumente“ (Objektivität, Reliabilität, Validität), „Gütekriterien des Forschungsdesigns“ (interne und externe Validität) und „Gütekriterien der statistischen Analyse“ (statistische Validität und praktische Bedeutsamkeit) (Krebs & Menold, 2014, S. 426). Des Weiteren schlugen Lienert & Raatz (1998) die Einteilung von „Gütekriterien eines Tests“ in „Hauptgütekriterien“ (Objektivität, Reliabilität, Validität) und

„Nebengütekriterien“ (normiert, vergleichbar, ökonomisch, nützlich) vor (Lienert & Raatz, 1998, S. 7). Im Rahmen dieser Hausarbeit wird nur der herrschende Konsens der Gütekriterien in Wissenschaft näher betrachtet und der Fokus auf Objektivität, Reliabilität, Validität gelegt.

2.3.1 Objektivität

Die Objektivität als Gütekriterium bezieht sich auf die Unabhängigkeit des Untersuchenden von dem Ergebnis (Lienert & Raatz, 1998). Die Daten, die aus einer Forschung resultieren sind demnach nicht objektiv, wenn sie mit dem Forschenden variieren. Die Objektivität von Ergebnissen können gemessen werden, indem der Korrelationskoeffizient zwischen mehreren Ergebnissen, derselben Stichprobe, die von verschiedenen Forschern hervorgehen, berechnet werden.

Die Objektivität als Gütekriterium wird von Lienert und Raatz (1998), sowie Krebs & Merlot (2014) und Himme (2007) in die Durchführungs-, Auswertungs- und Interpretationsobjektivität aufgeteilt.

Die Durchführungsobjektivität bezieht sich auf die Unabhängigkeit der Ergebnisse von zufälligen Variationen. Diese sei maximal so baldmöglichst standardisierte Verfahren die Ergebnisse produzieren und minimal, wenn das Vorgehen variiert (Lienert & Raatz, 1998) und die Untersuchung die Ergebnisse durch seine Vorstellungen oder sein Untersuchungsziel beeinflusst (Himme, 2007) werden. So würden verschiedene Forscher durch unterschiedliche Durchführungen der Datenerhebung zu unterschiedlichen Ergebnissen kommen.

Die Auswertungsobjektivität betrifft die „numerische oder kategoriale Auswertung“ (Lienert & Raatz, 1998, S. 8). Sie sei gering, wenn es mehrere Möglichkeiten der Auswertung von der „Schlüsselrichtung“ (Lienert & Raatz, 1998, S. 8) der Messdaten gäbe. Umso höher sei diese, wenn eine eindeutige Auswertung möglich sei und verschiedene Forschende auf dieselben Ergebnisse kommen. Einer geringen Auswertungssubjektivität kann vorgebeugt werden, indem eine sorgfältige Dokumentation der Datenaufbereitungsschritte sichergestellt wird. Desto eindeutiger und nachvollziehbarer die Aufbereitung desto objektiver könne die Auswertung auch zwischen mehreren Forschern erfolgen (Krebs & Menold, 2014).

Schließlich befasst sich die Interpretationsobjektivität mit dem Ausmaß der Unabhängigkeit von der Deutung der Messdaten von der interpretierenden Person. (Lienert & Raatz, 1998). Ist die Auslegung der Ergebnisse von mehreren Forschenden gleich, so ist die Interpretationssubjektivität gegeben. Kann jedoch das Ergebnis mehrdeutig ausgelegt werden, wenn verschiedene Forschende die Daten betrachten, dann ist die Interpretationsobjektivität nicht gegeben.

2.3.2 Reliabilität

Die Reliabilität ist das Kriterium, welches hilft einzuschätzen wie genau die Daten erfasst wurden in Bezug auf ihrer Stabilität über Zeit (Krebs & Menold, 2014). Es geht nicht darum, ob das was gemessen wurde auch genau das erfasst was es soll, sondern darum, dass der Messfehler so gering wie möglich gehalten wird, damit bei erneuter Durchführung das Ergebnis möglichst gleich ist (Lienert & Raatz, 1998). Desto kleiner der Messfehler desto höher die Reliabilität. Himme (2007) spricht davon, dass der Zufallsfehler bei einer reliablen Erfassung der Daten nicht vorhanden sei. Eine Form der Reliabilitätsprüfung ist die Wiederholungsreliabilität, die die zeitliche Stabilität der Messwerte überprüft. Es werden mit denselben Testinstrumenten dasselbe Untersuchungsobjekt zu zweit verschiedenen Zeitpunkten untersucht. Ist die Korrelation der Ergebnisse hoch so seien die Daten reliabel (Himme, 2007). Weitere Test sind die Paralleltestreliabilität, die interne Konsistenz und die Konsistenzanalyse (Lienert & Raatz, 1998), welche im Rahmen dieser Arbeit nicht näher erklärt werden.

2.3.3 Validität

Valide seien Daten, wenn diese genau das messen, was gemessen werden soll (Lienert & Raatz, 1998). Nach Krebs & Menold (2014) sei es das Ausmaß, mit dem ein Messinstrument das tatsächliche Phänomen erfassen, welches gemessen werden soll (Krebs & Menold, 2014). Ferner spricht Himme (2007) davon, dass der systematische Fehler null sein müsse und wie bei der Reliabilität der zufällige Fehler ebenfalls. So entspräche der beobachtete Wert dem wahren Wert der Grundgesamtheit (Himme, 2007). Zu überprüfen sei das mit der Korrelation zwischen den gemessenen und den wahren Werten, wenn es möglich ist letztere zu erfassen.

3. Methode

3.1 Fallauswahl

Zur Untersuchung der Objektivität, Reliabilität und Validität von Projektionen, die aus einem Machine Learning Prozess hervorgehen, wird im Folgendem das Projekt covid19-projections.com von Data Scientist Youyang Gu näher betrachtet. Das KI-basierte und datengesteuerte Modell ist im April 2020 entstanden, als die Corona Pandemie begann (Gu, et al., 2020). Das Ziel ist die Prognose und Schätzung von der Anzahl von Toten, Infizierten und Geimpften. Bis zu diesem Zeitpunkt beinhaltet das Modell Schätzungen für Todeszahlen im April 2020 bis Oktober 2020 für 71 Länder, Infektionsschätzungen für den Zeitraum von November 2020 bis März 2021 für die USA, sowie Prognosen über die Anzahl an Geimpften im Dezember 2020 bis März 2021, ebenfalls in den USA (Gu Y. , 2021). Für die Zwecke dieser Arbeit wird beispielhaft dieses Projekt herangezogen, um zu untersuchen, wie objektiv, reliabel und valide die Projektionen von Youyang Gu wirklich sind. Laut der World Health Organisation und dem Disease Control and Prevention US-Center half covid19-projections bei der Informierung von öffentlichen gesundheitspolitischen Entscheidungen mit (WHO, 2021). Aufgrund seines Beitrags zur Politikformulierung durch das Modell, welches mit einer Machine Learning Komponente zu Prognosen gelangt, wird deshalb hier untersucht. Darüber hinaus gilt es zu erforschen wie zuverlässig solche Daten sind, wenn es darum geht Menschenleben zu retten. Falsche Prognosen könnten zu falschen Entscheidungen führen, was in einer gefährlichen Situation, wie einer Pandemie, zu schwerwiegenden Konsequenzen führen kann. Beispielsweise werden auf Grundlage der Anzahl zukünftiger Infizierter Ressourcen wie Krankenhausbetten, Personal oder Beatmungsgeräte verteilt. Objektivität, Reliabilität und Validität von Daten, die als Orientierung von politischen Entscheidungen dienen, sollte daher eingehalten werden, damit das Krisenmanagement nicht fehlgeleitet wird.

Um die Objektivität, Reliabilität und Validität von Projektionen aus Machine Learning Prozessen richtig zu untersuchen, müssten mehrere Projekte untersucht werden. In Rahmen dieser Hausarbeit wird nur covid19-projections betrachtet. Deshalb kann nur bedingt eine Aussage geschlussfolgert werden, ob alle Daten die Gütekriterien einhalten.

3.2 Modell von covid19-projections.com

Die Datengrundlage des Modells ist das Johns-Hopkins-Institute[1], welches täglich neue Werte über Todeszahlen, Infizierten und Geimpften bereitstellt. Das Modell covid19-projections besteht aus zwei wesentlichen Teilen: dem SEIR Modell zur Infektionsmodellierung und der Machine Learning Komponente zur minimierung der Abweichungen von Schätzung und tatsächlichen Werten. Das SEIR Modell ist eine gebräuchliche Modellierungsmethode zur Simulation von Infektionsgeschehen. Das Modell

[1] https://coronavirus.jhu.edu/map.html

teilt die Bevölkerung in die Gruppen anfällige, ausgesetzte, infektiöse, genesene oder tote (susceptible, exposed, infectious, recovered) Personen und weist den Gruppen Wahrscheinlichkeiten zu (Gu Y. , 2021). Die Daten, die sich aus dem SEIR Modell ergeben sind, nur simulierte Infektions- und Todeszahlen, da in diesem Teil noch keine gesammelten Daten zum Vergleich herangezogen wurden. Die Simulation produziert ein einzelnes Parameter Paar, welches in dem nächsten Schritt in der Machine Learning Komponente mit den Werten des Johns-Hopkins-Institute verglichen werden (Siehe Abbildung 3). An diesem Schritt lernt das Programm von den echten Werten und produziert tausende weitere Parameter Paare, welche erneut den Simulator durchlaufen. Auf Grundlage dieser entstandenen Werte werden dann neue Simulationen durchgeführt, welche dann die Prognosen für zukünftige Infektionen sind. In den jeweiligen Zeiträumen wurden täglich die Simulationen evaluiert und auf dieser Basis neue Schätzungen produziert (Gu, et al., 2020). Im Folgenden wird die SEIR und die Machine Learning Komponente, sowie die Parameter und Annahmen, die diesen zugrunde liegen näher erläutert.

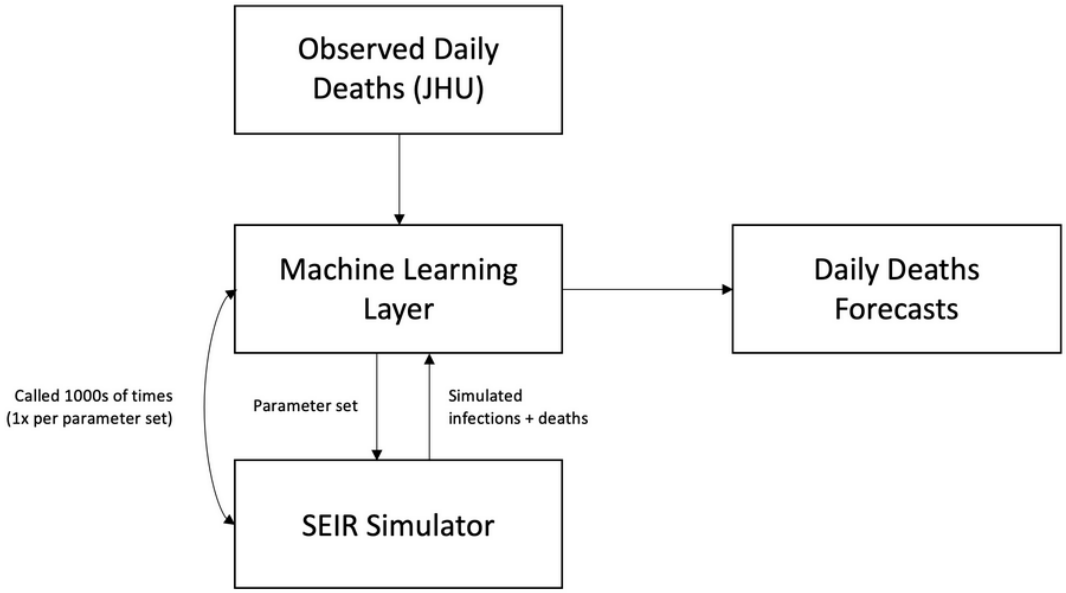

Abbildung 3 Modellaufbau covid19-projections, Quelle: covid19-projections.com

Im Weiterem werden einige wichtige epidemiologische Annahmen vorgestellt, welche dem Modell zugrunde liegen. Models of Infectious Disease Agent Study (MIDAS) [2] ist ein Netzwerk zur Unterstützung der Wissenschaft im Umgang mit Modellen und Prognosen. Es bietet Parameterempfehlungen für Konstanten, wie Infektions- oder Inkubationszeit, an (Gu Y. , 2021). Diese Werte variieren nicht signifikant innerhalb der Pandemie und entsprechen den Konsens des aktuellen Wissensstandes (Gu Y. , 2021). Es wird eine fünftägige Inkubationszeit und eine siebentägige Infektionszeit angenommen, sowie das

[2] https://midasnetwork.us/covid-19/#resources

eine Person ab dem zweiten Tag nach dem Beginn der Infektion bis zum achten Tag infektiös ist, mit einer höheren Infektionsgefahr in den Tagen 4-6. Diese Annahmen können sich zwar vom Einzelfall unterscheiden, aber stimmen laut MIDAS im Durchschnitt (Gu Y. , 2021). Darüber hinaus wird angenommen, dass eine Person nicht die gesamte Zeit infektiös ist, sondern nur die Hälfte und nur ein Fünftel sei hoch infektiös (Gu Y. , 2021). Über das Social Distancing wird für die jeweiligen Zeiträume und für das Land individuell entschieden. In den USA wird im jeweiligen Bundesstaat eine starke soziale Distanzierung bis zu dem jeweiligen Wiedereröffnungstag angenommen und hiernach eher moderates Social Distancing. Für europäische Länder wird bis Mai 2020 von starker sozialee Distanzierung ausgegangen. Mit starker sozialer Distanzierung seien die Ausgangsbeschränkungen, Kontaktverbote, Schließungen aller nicht systemrelevanten Orte zusammengefast, wobei die Infektionsrate um 60% sinke und der R Wert ebenfalls (Gu Y. , 2021). Mit moderatem Social Distancing sei die Lockerungsphase nach einem Lockdown gemeint. Es wird angenommen, dass einige Lockerungen stattfinden, jedoch trotzdem Maßnahmen eingehalten werden müssen, wie Hygienekonzepte (Gu Y. , 2021). Hierbei wird angenommen, dass die Infektionsrate um 0 bis 30 % steige. Nach diesem Zeitraum wird eine Abnahme der Infektionszahlen angenommen, da durch Masken, Hygienekonzepten und einer wachsenden Immunität der Bevölkerung die Ausbreitung des Virus langsamer stattfinde. Für den R Wert wird ab Juli 2020 die Sigmoisfunktion um die R_t Kurve der Neueröffnung zum approximieren angenommen. Um dessen Form zu modellieren, werden die Maximalwerte des R_t und der Infektionsrate, welche aus der Machine Learning Komponente hervorgehen. Weiterhin wird für die Winterzeit ab September angenommen, dass es unwahrscheinlich sei, dass die Todeszahlen erneut steigen, jedoch die Infektionszahlen, weil durchschnittlich mehr Zeit in Innenräumen verbracht würde, Schulneueröffnungen dazu beitragen könnten, Menschen wieder vermehrt Arbeiten gehen und über die Zeit Immunität verloren ginge (Gu Y. , 2021). Es wird aufgrund dessen mit einer 0 bis 0,5 %igem täglichen anstieg vom R_t Wert gerechnet. Schließlich wird der Infektionsschätzer aus dem aktuellen Wert der Infizierten mit fünf multipliziert, um alle Individuen mit einzuberechnen, auch die die nicht getestet wurden (Gu, et al., 2020). Weitere Annahmen, die an dieser Stelle zu weit ins Detail gehen können auf der Website covid19-projections.com eingesehen werden.

Nachdem der erste Teil des Modells näher beschrieben wurde, wird nun die zweite Komponente genau dargestellt. Der Machine Learning Teil des Modells benutz den mittleren quadratischen Fehler (Mean Square Error, MSE) zur Beurteilung der Parameter. MSE ist eine häufig verwendete Berechnung der Abweichung geschätzter Werte zu den wahren Werten (Schira, 2016). Formel (1) zeigt wie die durchschnittlichen Abweichungen der wahren Werte (X_T) von den Schätzungen (X_O) quadriert und aufsummiert werden. Das Quadrieren hat den Zweck größere Abweichungen zusätzlich zu verstärkt zu gewichten. Je höher der MSE desto fehlerhafter die geschätzten Parameter des SEIR Modells und desto größer die Abweichungen von den wahren Parametern der Grundgesamtheit.

$$(1) \qquad MSE(X_T) = E[(X_T - X_O)^2]$$

Mittels der Grid Search Methode werden die optimalen Parameter gewählt. Auf Basis dieser Werte und der im SEIR getroffenen Annahmen werden die Prognosen über die zukünftigen Todeszahlen, Impfzahlen und Infektionszahlen berechnet.

3.3 Vorgehen

Um nun zu beurteilen, wie objektiv, reliabel und valide diese Ergebnisse sind, werden jeweils die Gütekriterien in diesem Modell näher untersucht. Dabei wird einerseits eine erste Einschätzung getroffen Es werden Aspekte, die die Objektivität, Reliabilität, Validität beeinflussen können diskutiert und eingeschätzt. Geplant war es die Ergebnisse mit dem Modell zu replizieren und dann damit die jeweiligen Korrelationen zu berechnen, um auch empirisch die Gütekriterien zu bewerten. Das wurde dadurch verhindert, dass nicht das gesamte Modell von Youyang Gu veröffentlicht wurde. Nur der SEIR Simulationsteil ist zugänglich. Der zweite Teil mit dem Mashine Learning Part wurde nicht veröffentlicht. Eine Replikation dieses Teils ist nur bedingt möglich. Das dort verwendete Grid Search Verfahren wird durch zahlreiche Einstellungen festgelegt, welche von den von Youyang Gu abweichen könnten.

4. Analyse

4.1 Objektivität

Die Objektivität der Projektionen hängt von zahlreichen Aspekten ab wie im Kapitel 2.3.1 dargestellt. Die Durchführungsobjektivität ist dadurch gegeben, dass das Verfahren zur Berechnung der Projektionen maximal standardisiert ist. Sofern nichts an dem Code verändert wird, wird mit demselben Datensatz dasselbe Ergebnis repliziert. Jedoch wird das Kriterium der Durchführungsobjektivität nicht vollkommen erfüllt, da nicht das gesamte Modell veröffentlicht wurde. Außerdem treten unterschiedliche Ergebnisse der Parameter bei der jeweiligen Einteilung des Datensatzes in Test-Datensätze auf, wobei auf Grundlage der verschiedenen Stichproben, unterschiedliche Parameter berechnet werden können. Dadurch, dass das Verfahren tausendfach wiederholt wird, wird sich das Ergebnis jedes Mal den wahren Parametern annähern. Laut dem gesetzt der großen Zahlen würde sich ein Schätzer dem wahren Wert der Grundgesamtheit annähern, sofern die Stichprobengröße gegen Unendlich strebt (Schira, 2016). Die Durchführungsobjektivität wäre nicht gegeben, wenn beispielsweise immer andere Datensätze verwendet würden oder etwas am Code verändert wird und damit andere Parameter berechnet werden, die zu abweichenden Prognosen führen.

Die Auswertungsobjektivität hängt von den Maßeinheiten ab, die zur Messung verwendet werden und ob diese eine eindeutige Auswertung ermöglichen. Das Maß sind in covid19-projections die absolute Anzahl der Todes-, Infektions- und Impfzahlen. Diese absoluten Maße lassen sich eindeutig interpretiert, weil sie keine Proxis sind, sondern eins zu eins von dem Johns-Hopkins-Institute erfasst werden. Die Auswertungsobjektivität wäre beispielsweise umstritten, wenn es bei unterschiedlichen Forschern zu unterschiedlichen Interpretationen der Ergebnisse käme. Das kann beispielsweise bei der Auswertung von Fragebögen passieren. Jedoch wird hier ein absolutes Maß verwendet, welches die Auswertung eindeutig macht. Somit ist das Kriterium der Ausführungsobjektivität vollständig erfüllt.

Die Interpretationsobjektivität bezieht sich auf die Interpretation der Ergebnisse, nicht der Maßeinheiten wie bei der Auswertungsobjektivität. Auch hier hilft die Eindeutigkeit der Variablen Todes-, Infektions- und Impfzahlen dabei das Kriterium zu erfüllen. Abweichungen bei der Interpretation könnten bei der Darstellung der Verläufe mit Grafiken passieren. Gerade durch die Skallierung der Achsen kann eine Entwicklung optisch manipuliert werden.

Um die Objektivität empirisch zu prüfen, müsste der Korrelationskoeffizient von zwei Ergebnissen berechnet, die dieselbe Stichprobe auswerten. Ist die Korrelation hoch, ähneln sich die Ergebnisse und man kann von einer Forscherunabhängigen Objektivität sprechen. Im Rahmen dieser Hausarbeit wird das nicht umgesetzt und auf einen belastbaren empirischen Beweis verzichtet, da die fehlenden Bestandteile des Modells einen unerwarteten zeitlichen Aufwand darstellen.

4.2 Reliabilität

Die Reliabilität von Daten bezieht sich auf den Messfehler und wie präzise diese über die Zeit gemessen wurden. Dadurch, dass das Verfahren zur Berechnung der Parameter in der Simulation standardisiert ist und jeweils immer gleich durchgeführt wird, mit demselben Datensatz, lassen sich keine Unterschiede von Ergebnissen über die Zeit feststellen. Bei dem Grid Search Teil kann es zu Abweichungen in den Parametern kommen und demzufolge zu anderen Schätzungen für Todes-, Infektions- und Impfzahlen. Durch die zufällige Einteilung der Testdatensätzen, kann es zu einem Zufallsfehler kommen, bedingt durch die jeweilige Stichprobe. Dem wird jedoch damit vorgebeugt, dass dieses Verfahren tausende Male wiederholt wird. Laut dem Gesetz der großen Zahlen werden sich, mit steigender Anzahl an Wiederholungen, die geschätzten Parameter an die wahren Parameter der Grundgesamtheit annähern (Schira, 2016).

4.3 Validität

Valide sind die Projektionen, wenn sie das gewollte Phänomen messen können und die Werte das darstellen, was in der Grundgesamtheit tatsächlich passiert. Eine fehlerhafte Erfassung der Daten von Johns-Hopkins-Institute könnte eine mögliche Ursache für darauffolgende Fehlschätzungen der Parameter sein. Andere Gründe für Abweichungen der Schätzungen von den tatsächlichen Werten für Todes-, Infektions- und Impfzahlen können die Einschränkungen durch die zahlreichen Annahmen sein. Annahmen sind zwar wichtig, um die Komplexität des Modells zu reduzieren und das Geschehen der echten Welt zu modellieren, jedoch sind diese häufigen Fehlerquellen, wie man am Beispiel von Florida sehen kann. Die Annahme, dass sich der R Wert um nur einen begrenzen Prozentsatz erhöht führte hierzu, dass die Projektionen signifikant unterschätzt wurden. Der R Wert war schon sehr hoch und hat sich dementsprechend unerwartet weiter erhöht, was die Infektionen schnell ansteigen ließ, als zusätzlich Lockerungen in dem Bundesstaat eingeführt wurden. Einzelfälle wie diese zeigen wie wichtig es ist, Annahmen möglichst richtig festzulegen, um Fehlschätzungen zu vermeiden. Es gibt jedoch immer die Gefahr Ausreißer zu über- oder unterschätzen. Hinzu kommt, dass diese Festlegungen noch wissenschaftlich revidiert werden können, wenn neue Erkenntnisse im Laufe der Erforschung des Virus bekannt werden. Es wäre also möglich gewesen, dass die Annahmen grundlegend falsch sind und es dadurch zu Abweichungen der Projektionen von den tatsächlichen Fallzahlen kommt. Trotz dieser Probleme ist das Modell erfolgreich mit einer Genauigkeit von 96 %. Wie man in Abbildung 4 sehen kann ist covid19-projections eines der verlässlichsten Modelle gewesen, verglichen mit 40 weiteren, unter anderem mit Projekten vom MIT und Google.

Best-performing models for US state-by-state - 4-week ahead forecasts

We take the weekly projections sent to the CDC for all 50 states (+DC), and compare their incident deaths projections for 4 weeks ahead with each state's true reported incident deaths for those 4 weeks. We take the mean of the absolute errors for each state.

Baseline is a simple model where we take the mean of the previous week's daily deaths to make all future forecasts. For example, for October 5 projections, we use the average daily deaths from September 28 to October 4 for all future projections (this is a constant number).

Projections in red = failed to outperform the baseline model of simply using the previous week's average deaths to make all future projections.

Team category: blue = academic institution; purple = private company; orange = government/military; brown = independent

Note: For fair comparisons, we are only considering models that have 3+ submissions.

Source: https://github.com/youyanggu/covid19-forecast-hub-evaluation

	Mean absolute error for 4-week ahead forecasts																												
	4/20 - 5/16	4/27 - 5/23	5/4 - 5/30	5/11 - 6/6	5/18 - 6/13	5/25 - 6/20	6/1 - 6/27	6/1 - 6/27	6/15 - 7/11	6/22 - 7/18	6/29 - 7/25	7/6 - 8/1	7/13 - 8/8	7/20 - 8/15	7/27 - 8/22	8/3 - 8/29	8/10 - 9/5	8/17 - 9/12	8/24 - 9/19	8/31 - 9/26	9/7 - 10/3	9/14 - 10/10	9/21 - 10/17	9/28 - 10/24	10/5 - 10/31	% weeks beat baseline
COVIDhub Ensemble (combination of various models)		190	100	141	117	122	120	95	87	87	98	175	162	116	111	74	71	53	64	72	66	73	74	79	90	100%
YYG - covid19-projections.com	278	234	131	141	172	142	91	100	98	121	138	205	132	140	137	100	80	64	67	70	81	98	89	88	72	96%
UMass-MB - University of Massachusetts, Amherst		757	271	123	102	61	147	86	96	149	192	176	121	135	194	134	103	75	94	109	67	87	81	69	85	83%
UCLA - University of California, Los Angeles			250	209	107	99	110	120	111	133	193	234	201	200	147	116	105	108	89	89	89	76	101	102	124	96%
Oliver Wyman								101	98	140	163	184	180	134	119	100	72	57	68	91	68	78	91	128	88	94%
LANL - Los Alamos National Laboratory	401	318	166	133	129	112	110	99	101	114	160	221	239	254	278	226	161	151	139	132	127	132	114	133	164	44%
Baseline (use previous week's average daily deaths)	352	339	290	309	264	207	173	187	163	165	323	265	233	202	153	119	107	124	110	106	102	88	101	108	99	---
MIT_CovidAnalytics - MIT		259	305	299	244	155	127	168	170	152	183	238	184	150	136	145	129	93	122	121	122	118	122	141	132	54%
IowaStateLW - Iowa State University		233	320	N/A	153	129	160	130	129	137	231	256	240	207	163	153	N/A	145	172	113	113	99	141	109	114	41%
Covid19Sim - COVID-19 Simulator						177	194	173	119	115	175	203	136	138	132	142	N/A	N/A	315	87	112	98	109	109	114	56%
USC - University of Southern California											183	253	277	180	190	93	92	76	102	92	94	84	86	98	91	87%
IHME - Institute for Health Metrics and Evaluation	528	552	237	178	194	N/A	176	115	126	92	137	210	N/A	204	170	165	138	N/A	253	210	165	N/A	135	201	N/A	40%
COVIDhub Baseline	688	332	288	371	274	241	186	177	181	182	343	276	261	220	161	151	114	144	138	129	118	94	122	112	101	---
LNQ - LockNQuay														125	132	67	87	94	70	67	68	106	87	76	95	92%
CMU - Carnegie Mellon University (Delphi)														156	138	82	125	73	91	57	62	93	86	88	89	83%
JCB - John Burant															111	111	85	74	81	74	72	83	74	76	96	100%
MOBS - Northeastern University	622	411	460	442	265	155	135	137	148	183	231	256	249	231	227	420	134	114	124	147	107	132	127	175	137	28%
UT - University of Texas, Austin	665	549	451	N/A	233	123	108	118	127	136	143	229	181	247	454	616	N/A	284	125	N/A	N/A	146	154	231	104	43%
CU-select - Columbia University	428	324	222	208	228	208	330	312	271	479	709	293	170	210	225	184	110	171	136	155	121	142	155	190	136	20%
UA - University of Arizona						295	233	262	151	101	259	270	266	150	117	137	130	119	108	194	182	152	137	133	114	35%
GT-DeepCOVID - Georgia Institute of Technology												302	285	239	199	165	141	105	94	129	117	93	112	99	116	21%
JHU_IDD - Johns Hopkins University					1108	432	384	376	227	274	264	281	244	257	238	240	240	255	159	135	103	100	91	87	115	14%
USACE - US Army Engineer Research and Development Center					248	194	256	208	120	148	244	165	173	519	321	297	253	229	207	208	215	222	250	246	N/A	35%
Karlen - Karlen Working Group														834	393	323	207	166	112	99	90	87	89	94	90	50%
CEID - University of Georgia																	106	140	132	125	108	94	118	111	100	11%
Steve McConnell																			129	107	73	70	81	121	106	43%
PSI - Predictive Science Inc					332	209	154	370	207	246	272	362	371	229	467	737	270	298	169	157	185	138	115	132	166	10%
NotreDame-mobility - University of Notre Dame										264	441	286	242	237	271	329	269	155	132	111	134	170	143	152	134	0%
DDS - Discrete Dynamical Systems															776	390	946	183	162	82	101	103	102	125	152	18%
Auquan - Auquan Data Science					347	365	370	763	837	150	209	309	N/A	N/A	N/A	206	141	151	158	N/A	N/A	N/A	N/A	N/A	N/A	17%
MIT_CritData - MIT																					96	121	82	89	100	60%
MITCovAlliance - MIT											304	471	555	458	455	340	N/A	440	N/A	N/A	154	205	244	109	N/A	9%
EpiForecasts - LSHTM																		110	132	150	168	157	203	206	246	13%
Robert Walraven												476	486	1787	267	187	671	185	189	164	196	224	229	235	196	0%
UCSD - University of California San Diego																					106	116	138	192	134	0%
Google Cloud AI																				129	139	N/A	169	110	155	0%
UMich - University of Michigan																	394	N/A	N/A	102	211	253	272	163	137	14%
JHUAPL - Johns Hopkins University																				222	243	211	168	157	110	0%
Columbia_UNC - Columbia University/University of North Carolina																					169	144	268	256	173	0%
Walmart Labs																					202	193	197	212	229	0%
TTU - Texas Tech University																		3188	N/A	N/A	N/A	656	N/A	723	364	0%
Median Mean Abs Error	*478*	*328*	*271*	*208*	*233*	*166*	*160*	*152*	*128*	*148*	*209*	*256*	*239*	*207*	*190*	*159*	*129*	*132*	*127*	*112*	*108*	*99*	*112*	*111*	*110*	

Abbildung 4 Vergleich von Covid-19 Schätzmodellen, Quelle: https://covid19-projections.com/about/#historical-performance

5. Fazit

Abschließend lässt sich festhalten, dass die Projektionen durch den nicht veröffentlichten Teil des Modells nur bedingt objektiv waren. Die Ergebnisse können bei der Replikation geringfügig abweichen, wenn die Einstellungen nicht gleich festgelegt werden. Deswegen können Replikationen von Forschendem zu Forschendem Abweichungen aufweisen. Das Kriterium der Durchführungsobjektivität ist erfüllt, sofern die die Anpassung der Parameter mit Grid Search oft genug durchgeführt wird. Die Auswertungsobjektivität ist komplett gegeben, genauso wie die Interpretationsobjektivität. Das Kriterium der Reliabilität ist auch erfüllt, wenn die Schätzungen oft genug wiederholt werden. Die Daten sind außerdem, in diesem Fall valide, da sie in einem Hohen Maße präzise waren. Das Modell konnte mit einer hohen Genauigkeit Todes-, Infektions- und Impfzahlen vorhersagen und diente als eine teils objektive, aber reliable und valide Quelle für politische Entscheidungen. Jedoch gilt das nicht für jedes andere Machine Learning Modell, da die Gütekriterien von zahlreichen Faktoren abhängen, wie beispielsweise die getroffenen Annahmen, die Verfahren zur Parameter Anpassung, die Datengrundlage oder Eindeutigkeit der Daten. Deswegen sei es im Interesse der Gesellschaft solche neuen Methoden der Schätzungen gründlich zu untersuchen, bevor sie als Grundlage für möglicherweise überlebenswichtige Entscheidungen herangezogen werden. Um eine quantitative Aussage über die Güte von Projektionen aus Machine Learning Verfahren abzuleiten, müsste Vielzahl von Projekten gründlich untersucht werden und auch tatsächlich repliziert, sowie die jeweiligen Korrelationen der Daten berechnet werden, was im Rahmen dieser Hausarbeit nicht möglich ist.

Literaturverzeichnis

Alzubi, J., Nayyar, A., & Kumar, A. (2018). Machine Learning from Theory to Algorithms: An Overview. *Journal of Physics: Conference Series*.

Gu, Y. (27. 08 2021). *covid19-projections.com*. Von https://covid19-projections.com/about/ abgerufen

Gu, Y., Ray, E. L., Wattanachit, N., Niemi, J., Kanji, A. H., House, K., . . . Tomar, V. (2020). *Ensemble Forecast of Coronavirus Disease 2019 (COVID-19) in the U.S.* US Government.

Heuermann, R., Engel, A., & Lucke, J. v. (2018). Digitalisierung: Bergriff, Ziele und Steuerung. In R. Heuermann, M. Tomendal, & C. Bressem, *Digitalisierung in Bung, Ländern und Gemeinden - IT-Organisation, Management und Empfehlungen* (S. 9-50). Springer Berlin Heidelberg.

Himme, A. (2007). Gütekriterien der Messung: Reliabilität, Validität und Generalisierbarkeit. In S. Albers, D. Klappen, U. Konradt, A. Walter, & J. Wolf, *Methodik der empirischen Forschung* (S. 375-390). Springer.

Höchtel, J., Parycek, P., & Schöllhammer, R. (2016). Big Data in the policy cycle: Policy decision making in the digital era. *Journal of Organizational Computing and Electronic Commerce*, S. 147-169.

Jann, W., & Wegrich, K. (2008). Phasenmodelle und Polikprozesse: Der Policy Cycle. In K. Schubert, & N. C. Bandelow, *Lehrbuch der Politikfeldanalyse 2.0* (S. 75-113). München: Oldenburg Wissenschaftsverlag GmbH.

Kamateri, E., Panopoulou, E., Tambouris, E., Tarabanis, K., Ojo, A., Lee, D., & Price, D. (2015). A Comparative Analysis of Tools and Technologies for Policy Making. In M. Janssen, M. A. Wimmer, & A. Deljoo, *Policy Practice and Digital Science* (S. 125-156). Springer.

Krebs, D., & Menold, N. (2014). Gütekriterien quantitativer Sozialforschung. In N. Baur, & J. Blasius, *Handbuch der Mehtoden empirischer Sozialforschung* (S. 425-438). Wiesbaden: Springer Fachmedien Wiesbaden .

Lienert, G. A., & Raatz, U. (1998). *Testaufbau und Testanalyse.* Psychologie Varlags Union, Weinheim.

Schira, J. (2016). *Statistische Methoden der VWL und BWL.* Springer.

Schneider, V., & Janning, F. (2006). *Politikfeldanalyse - Akteure, Diskurse und Netzwerke in der öffentlichen Politik.* Wiesbaden: VS Verlag für Sozialwissenschaften.

Schrittwieser, J., Antonoglou, I., Hubert, T., Simonyan, K., Sifre, L., Schmitt, S., . . . Silver, D. (2020). *Mastering Atari, Go, chess and shogi by planning with a learned model.* Von DeepMind. abgerufen

Thierer, A., O'Sullivan Castillo, A., & Russell, R. (2017). *Artificial Intelligence and Public Policy.* Arlington: Merctarus Center, Georg Mason University.

Tsebelis, G. (1995). Decision Making in Political Systems: Veto Players in Presidentialism, Parliamentarism, Multicameralism and Multipartyism. *British Journal of Political Science*, S. 289–325.

Wang, P. (2008). *What Do You Mean by "AI"?*

WHO. (27. 08 2021). *World Health Organisation*. Von https://www.who.int/data/technical-advisory-group/covid-19--mortality-assessment/membership abgerufen

Winkler, P. (2010). *Empirische Wirtschaftsforschung und Ökonometrie.* Springer.

Anhang

1. Anhang: Mashine Learning Schritte

Jedem Machine Learning Modell liegen die folgenden Schritte zu Grunde. Die Datenerhebung und Aufbereitung, die Variablenauswahl, Wahl der geeigneten Algorithmen, Modell, sowie Parameter, das Trainieren des Programms mit einem Bruchteil des Datensatzes und schließlich die Evaluation der Ergebnisse (Alzubi, Nayyar, & Kumar, 2018). Bei der Erhebung und Aufbereitung werden die Datensätze auf Ausreiser überprüft oder fehlende Daten ersetz oder gelöscht, Variablen skaliert für einfache Interpretation, neue Variablen erstellt, welche für das Vorhaben gebraucht werden. Der zweite Schritt in einem Machine Learning Modell ist die Auswahl der Variablen. Nicht alle erfassten Merkmale eines Datensatzes werden für ein Programm benötigt, weswegen eine Auswahl getroffen wird. Diese hängt von dem Problem ab und kann erst an konkreten Beispielen näher erklärt werden. Der nächste Schritt ist die Entscheidung über den geeigneten Algorithmus. Dies hängt unter anderem von der Art des Problems ab. In der Data Science gibt es fünf Arten von Problemen: das Klassifizierungsproblem, Anomalieerkennung, Regression, Clusterprobleme und das Reinforcment Learning Problem (Alzubi, Nayyar, & Kumar, 2018). Die Klassifizierungsprobleme (classifiction Problem) beschäftigen sich mit binären Variablen, die auf Grundlage von anderen Merkmalen geschätzt werden. Beispielsweise Ja/Nein oder True/False als geschätzte Variablen. Konkreter, ob man beispielsweise eine Aktie verkaufen oder halten sollte. Eine weitere Art von typischen Machine Learning Problem ist die Anomalieerkennung, welche darauf spezialisiert ist ungewöhnliche Muster in Datensätzen zu finden bzw. nach wichtigen Ausreisern zu suchen. Banken wenden dies an, um bei unüblichen Transaktionen ihrer Kunden gewarnt zu werden. Das Regressionsproblem beschäftigt sich mit der Schätzung von kategorialen oder kontinuierlichen Variablen, die auf Grundlage von anderen Merkmalen erklärt werden. Ein geläufiges Beispiel ist hier die Schätzung des Gehaltes einer Person, vor dem Hintergrund der Bildungsjahre, des IQs und Geschlechtes als erklärende Variablen (Alzubi, Nayyar, & Kumar, 2018). Das Clusterproblem beschäftigt sich mit der Gruppierung von Daten in Gruppen mit ähnlichen Eigenschaften. Ein alltägliches Anwendungsbeispiel ist die Einteilung von E-Mails in den Spam Ordner (Alzubi, Nayyar, & Kumar, 2018). Schließlich befasst sich das Reinforcement Learning Problem mit dem Lernen aus Daten und *trail and error* Verfahren, mit Formeln für Abstrafung bei Fehleinschätzungen und Honorierung von richtigen Entscheidungen (Alzubi, Nayyar, & Kumar, 2018). Eine weitere Einteilung von Arten von Problemen, um die richtigen Algorithmen zu wählen ist die in „supervised“, „unsupervised“, „semi-supervised“, „unsupervised learning“, „reinforcement Learning“, „evolutunary Learning“, „ensamble Learning“, „artificial neutral network“, „Instance-based Learning“, „dimensionality reduction“ Algorithmen und hybrides Lernen (Alzubi, Nayyar, & Kumar, 2018, S. 6). Aufgrund des begrenzten Umfanges dieser Arbeit werden diese einzelnen Einteilungen nicht näher erläutert und nur auf die Zusammenfassung

von Alzubi et al. (2018) verwiesen. Schließlich kann anhand der Probleme ein geeigneter Algorithmus gewählt werden. Im Laufe der Forschung haben sich die folgenden Vorgehen behauptet: der Decision Tree für Klassifizierungsprobleme, Naive Bayes für Wahrscheinlichkeitsschätzung, Supportet Vector Machienes, Regressionsanalyse, K-Mean Klusterverfahren, K-Nearest Neighbours, Random Forest und Pricipal Component Algorithms. Auch diese werden aus Gründen des Platzmangels nicht näher erläutert, sondern nur auf die Zusammenfassung von Alzubi et al. (2018) verwiesen.

Im dritten Schritt eines Machine Learning Prozesses wird das geeignete und Parameter ausgewählt. Selbst wenn die meisten Prozesse rein automatisch ablaufen, braucht es immer noch das Verständnis eines Data Scientist, um einzuschätzen welche Modelle und Parameter am geeignetsten für das Vorhaben sind. (Alzubi, Nayyar, & Kumar, 2018)

Im vorletzten Schritt wird der Algorithmus mit einem Teil des Datensatzes gespeist. Es wird nicht der komplette Datensatz benutz, damit es nicht zu einer Überanpassung (overfitting) kommt. Das ist ein häufiges Problem, bei dem das Modell zu genau versucht die Daten zu erklären und dabei das eigentliche Phänomen übersieht und die zufällige Variation miterklärt. Damit die Ursache und Wirkung, die die Forscher wirklich interessiert erfasst wird, wird absichtlich eine Zufallsstichprobe aus dem Datensatz erhoben und mit dem Algorithmus ausgewertet (Alzubi, Nayyar, & Kumar, 2018).

Auf Grundlage dieser Ergebnisse kommt es dann zur Evaluation der Modelle. Die Präzession der Werte kann mit vielen mathematischen Hilfsmitteln wie dem Mean Square Error (MSE) für kontinuierliche Variablen oder beispielsweise dem Accuracy Maß für binäre Variablen gemessen werden. Auch diese Evaluation wird in Algorithmen verpackt. Weiterhin kann ein Programm aus seinen Fehlern lernen, indem die Fehler minimiert und die Präzision der Parameter maximiert wird, wodurch diese an die Schätzung angepasst werden (Alzubi, Nayyar, & Kumar, 2018). Das nennt man auch hyperparameter tuning.

2. Anhang: Einflüsse im Politikformulierungsprozess

So haben beispielsweise gut organisierte oder einflussreiche Interessengruppen mehr Einfluss. Das Meinungsbild der Bürger wird unter dem Motiv der Wiederwahl der Regierung mitberücksichtigt. Berichte, Studien und wissenschaftliche Erkenntnisse haben ebenfalls einen Einfluss, der durch die politische Beratung oder durch die Erarbeitung in Arbeitsausschüssen seinen Weg in den Politikformulierungsprozess findet (Jann & Wegrich, 2008). Darüber hinaus entscheidet auch die ideologische Ausrichtung der Regierungspartei bzw. der Koalition oder des Ministers des Federführenden Referats, mit über die konkrete Formulierung (Tsebelis, 1995). Die Machkonstellationen spielen ebenfalls eine große Rolle, wenn es um Konsensfindung geht. Sind viele Akteure beteiligt und die Machstrukturen symmetrisch wird es schwerer eine Lösung zu finden mit der alle Vetospieler einverstanden sind (Tsebelis,

1995). Die Dringlichkeit des Problems ist auch ein entscheidender Einfluss, so kann es bei Zeitdruck zu handwerklich unausgereiften Entscheidungen kommen oder bei Problemen ohne Dringlichkeit zu längeren Diskussionen. Der Einfluss der politischen Tradition kann am Beispiel von Budget- oder Haushaltsplanung veranschaulicht werden. Hat ein Ministerium schon immer einen größeren Anteil von Haushaltsgeldern zugewiesen bekommen, fällt es schwer dieses Budget in der nächsten Periode zu kürzen und auf andere Ressorts umzuverteilen (Jann & Wegrich, 2008).

Eidesstaatliche Erklärung

Hiermit versichere ich, dass ich die Hausarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe, alle Ausführungen, die anderen Schriften wörtlich oder sinngemäß entnommen wurden, kenntlich gemacht sind und die Arbeit in gleicher oder ähnlicher Fassung noch nicht Bestandteil einer Studien- oder Prüfungsleistung war.

Potsdam, 1.10.2021

Einverständniserklärung

Ich erkläre mich damit einverstanden, meine schriftliche Arbeit (Titel einfügen) in elektronischer Form einzureichen. Ich bin damit einverstanden, dass die Arbeit mit Hilfe einer Plagiaterkennungssoftware (wie z.B. Turnitin) einer Überprüfung unterzogen werden kann.

Name: Tsymboulova
Vorname: Anastasia
Matrikel-Nummer: 804385
Studiengang: Politik und Wirtschaft
Thema der Arbeit: Machine Learning Prozesse im Policy Cycle am Beispiel von co-vid19-projections.com – Eine Untersuchung der Reliabilität, Validität und Objektivität der Projektionen

Unterschrift: